

PREVISÃO DE SOBREVIVÊNCIA EM DOENTES COM CIRROSE

Madalena Passos^{1†}, Mariana Almeida^{1†}, Mariana Ribeiro^{1†}

¹Universidade do Minho, Braga, Portugal.

Contributing authors: pg54023@alunos.uminho.pt;
pg54062@alunos.uminho.pt; pg54061@alunos.uminho.pt;

[†]These authors contributed equally to this work.

Abstract

A cirrose hepática representa uma fase avançada de fibrose no fígado, resultante de diversas condições como hepatite e alcoolismo crónico. Este artigo utiliza dados provenientes do ensaio clínico da *Mayo Clinic* sobre cirrose biliar primária realizado entre 1974 e 1984. A rápida e precisa identificação da condição é crucial para a implementação de intervenções eficazes, capazes de atenuar danos hepáticos e prevenir complicações, especialmente nas fases iniciais da doença. O foco da pesquisa é a avaliação de técnicas de *Data Mining (DM)*, utilizando dados clínicos, para prever os desfechos de sobrevivência em doentes com cirrose. O estudo utiliza a metodologia de CRISP-DM, analisando diferentes algoritmos de classificação, incluindo *k-Nearest Neighbors*, *Random Forest*, *Árvores de Decisão*, *Gradient Boosting* e *Naïve Bayes*. A eficácia do modelo é avaliada, destacando o *Random Forest* com *Holdout Sampling* e uma razão de 0.7, cujas métricas de desempenho rondam os 80%. Foram também analisadas entre os atributos nominais de forma a descobrir possíveis padrões de associação.

Keywords: cirrose biliar primária; *Data Mining*; CRISP-DM; Classificação

1 Introdução

A cirrose é uma doença hepática caracterizada pela elevada cicatrização do tecido do fígado [1]. Esta condição clínica é gerada aquando do consumo excessivo de álcool, mas pode ser, também, proveniente de outras causas que levam a lesões constantes neste tecido, como infeções.

O conjunto de dados escolhido é composto por informações detalhadas sobre doentes diagnosticados com cirrose hepática a partir de um ensaio clínico conduzido pela *Mayo Clinic* sobre cirrose biliar primária, realizado entre os anos de 1974 e 1984 [2]. Este conjunto abrangente reúne variáveis clínicas e de diagnóstico. A escolha deste *dataset* [2] visa não apenas entender os fatores determinantes da cirrose, mas também antecipar padrões que podem orientar intervenções médicas e políticas de saúde.

Além de identificar padrões de comportamento e fatores de risco associados à cirrose hepática, através do desenvolvimento de regras de associação e descoberta de correlações, o artigo visa também contribuir para a construção de modelos de previsão que possam ser aplicados na prevenção e tratamento eficaz da doença. Com efeito, o objetivo principal do estudo será prever o atributo (*target*) *Status* que representa a sobrevivência, a não sobrevivência ou necessidade de transplante do doente com doença hepática. Esta previsão, por sua vez, possibilitará uma alocação mais eficiente de recursos e esforços por parte dos profissionais de saúde. Além disso, os casos em que a previsão aponta para uma menor probabilidade de sobrevivência podem ser explorados em pesquisas adicionais, visando o desenvolvimento de abordagens inovadoras no tratamento da cirrose biliar primária [3].

Neste contexto, será utilizado um processo de aprendizagem e extração de conhecimento focado na análise de informações relacionadas a doentes com cirrose hepática, utilizando técnicas de *data mining* [1]. A metodologia adotada segue o processo de CRISP-DM, desde a compreensão inicial do negócio, *Business Understanding*, a compreensão dos dados recolhidos, *Data Understanding*, a preparação dos dados, *Data Preparation*, até a aplicação de algoritmos de aprendizagem de máquina, *Modeling*, e a avaliação rigorosa dos resultados obtidos [4]. As etapas são fluídas de forma a garantir os melhores resultados do processo [5].

Ao longo deste documento, serão apresentadas detalhadamente as diversas etapas do processo de data mining, apresentando as ferramentas utilizadas e resultados obtidos.

2 Business Understanding

Nesta condição clínica, o diagnóstico precoce é fulcral, uma vez que existem métodos para controlar os danos causados e, em raros casos, alcançar uma cura total. Porém, caso tal não aconteça, devido à perda de função hepática, podem ser atingidos estados clínicos graves como insuficiência hepática, icterícia, cancro de fígado, podendo causar efetivamente a morte do indivíduo[6].

De modo a evitar este desfecho e a prever se o problema poderia ser resolvido recorrendo a transplante, é essencial reconhecer padrões que levem aos mesmos. Nesse seguimento estão a ser investigados algoritmos capazes de prever a presença de cirrose, carenciando, porém, da capacidade de prever os estadios desta doença. Neste projeto, pretende-se atingir valores de *accuracy* relativamente elevados, procurando prever, não só a presença ou ausência da doença, mas também priorizando, fundamentalmente, a identificação de doentes candidatos a transplante[7, 8].

Para atingir esse objetivo, pretende-se aplicar algoritmos de *Data Mining* que permitam a clarificação da relação entre os atributos e estes e o atributo objetivo

(*target*), podendo assim eliminar aqueles cujo impacto não seja tão significativo e ajustar parâmetros de outros, como os valores em falta, de modo a obter um conjunto de dados passível de avaliação.

Após este processo, serão aplicadas técnicas de previsão de modo a completar o modelo em questão e obter informação relativamente confiável sobre o estadio da doença e auxiliar no processo de decisão de quais os passos seguintes a tomar pelos médicos.

De modo geral, o objetivo do negócio do estudo presente neste artigo é a antecipação eficaz dos desfechos de sobrevivência em pacientes com cirrose hepática. A análise visa identificar padrões e fatores prognósticos associados à cirrose, permitindo intervenções médicas oportunas.

3 Data Understanding

O dataset escolhido, *cirrhosis.csv*, contém 418 registos de informação sobre pacientes que apresentam doença hepática, nomeadamente 20 colunas de dados clínicos. Assim, estas colunas traduzem-se em 20 atributos de vários tipos de dados. Na Tabela 1, encontram-se os significados destes atributos.

Table 1: Definição dos atributos presentes no *dataset cirrhosis*.

Atributo	Significado
ID	Identificador único
NDays	Nº de dias entre o registo da informação e a morte, transplante ou análise do estudo
Drug	Tipo de droga: D-penicillamine ou Placebo
Age	Idade (em dias)
Sex	Sexo: M (Masculino) ou F (Feminino)
Ascites	Presença de ascites: Y (Sim) ou N (Não)
Hepatomegaly	Presença de hepatomegalia: Y (Sim) ou N (Não)
Spiders	Presença de aranhas vasculares: Y(Sim) ou N (Não)
Edema	Presença de Edema: N (sem edema e sem terapia diurética para edema), S (edema presente sem diuréticos, ou edema tratado por diuréticos), ou Y (edema apesar de terapia diurética)
Bilirubin	Sérum de Bilirrubina (em mg/dl)
Cholesterol	Sérum de Colesterol (em mg/dl)
Albumin	Albumina (em gm/dl)
Copper	Cobre na Urina (em ug/dia)
AlkPhos	Fosfatase Alcalina (em U/L)
SGOT	Transaminase glutâmico-oxalacética (em U/ml)
Triglycerides	Triglicerídeos (em mg/dl)
Platelets	Plaquetas por cm3(ml/100)
Prothrombin	Tempo de protrombina (em s)
Stage	Estadio da doença: 1(Normal), 2 (Fígado Gordo), 3 (Fibrose do fígado) ou 4 (Cirrose)
Status	Estado do paciente: C (questionado), CL (questionado para transplante), D (morte)

Para compreender a informação e os tipos de atributos presentes, bem como a existência de representatividade ou valores ausentes foi realizada uma caracterização de cada atributo. Na Tabela 2, encontram-se os tipos de dados de cada atributo,

o número de valores ausentes, o valor mínimo, máximo, média e desvio padrão dos atributos numéricos e, no caso de atributos nominais, o conjunto de valores possíveis e a moda.

Table 2: Caracterização dos atributos presentes no *dataset cirrhosis*.

Atributo	Tipo de atributo	Valores ausentes	Intervalos de valores	Média/Moda	Desvio Padrão
Id	Inteiro	0	[1;418]	-	-
Age	Inteiro	0	[9598 ; 28650]	18533.352	-
Sex	Binominal	0	{F; M}	F	-
NDays	Inteiro	0	[41 ; 4795]	1917.782	1104.673
Drug	Nominal	106	{D-Penicillamine ; Placebo}	D-Penicillamine	-
Ascites	Binominal	106	{Y ; N}	N	-
Hepatomegaly	Binominal	106	{Y ; N}	Y	-
Spiders	Binominal	106	{Y ; N}	N	-
Edema	Binominal	0	{Y ; N}	N	-
Cholesterol	Inteiro	134	[120 ; 1775]	369.511	231.945
Albumin	Real	0	[1.960 ; 4.640]	3.497	0.425
Copper	Inteiro	108	[4 ; 588]	97.648	85.614
AlkPhos	Real	106	[289 ; 13862.4]	1982.656	2140.389
SGOT	Real	106	[26.350 ; 457.250]	122.556	56.700
Platelets	Inteiro	11	[62 ; 721]	257.025	98.326
Bilirubin	Real	0	[0.300 ; 28]	3.221	4.408
Tryglicerides	Inteiro	136	[33 ; 598]	124.702	65.149
Prothrombin	Real	2	[9 ; 18]	10.732	1.022
Stage	Nominal	6	{1 ; 2 ; 3 ; 4}	3	-
Status	Nominal	0	{CL ; C ; D}	C	-

Através da análise da informação da Tabela 2, é possível averiguar a inexistência de *outliers*. Esta conclusão foi suportada, também, pela análise de gráficos *box plot* para cada atributo. No *dataset* apresentado, o atributo *label/target* é o atributo *Status*, que representa a sobrevivência, a não sobrevivência ou necessidade de transplante do doente com doença hepática.

Para analisar o possível enviesamento de dados, foi desenhado um gráfico da contagem dos casos CL, C, D do atributo *Status*, presente na Figura 1. Como se pode verificar, a contagem de casos CL, isto é, em situação de necessidade de transplante, é muito menor quando comparada às situações de sobrevivência sem transplante e de morte. Assim, conclui-se que o *dataset* não se encontra devidamente balanceado, podendo ter influências negativas na criação de modelos de previsão [4]. Desta forma, o *dataset* terá de ser tratado nesse sentido na fase seguinte do processo de *Data Mining*.




Fig. 1: Distribuição dos valores do atributo *target*.

Para tentar entender as correlações entre alguns atributos foram desenvolvidos gráficos de barras, com os dados agrupados entre os atributos e o atributo *target Status*. O gráfico obtido para o atributo *Stage* encontra-se na Figura 2.




Fig. 2: Associação do atributo *Stage* e atributo *Status*, onde os pacientes vivos são representados pelas barras verdes, os pacientes falecidos pelas barras azuis e os pacientes transplantados pelas barras laranja.

Estes atributos *Stage* e *Status* parecem estar relacionados. Como se pode observar no gráfico um estadio de doença mais avançado pode significar uma maior probabilidade de morte. Da mesma forma, um estadio de doença menos avançado parece diminuir a probabilidade de morte bem como a probabilidade de transplante. Da mesma forma, foi desenvolvido um gráfico semelhante para o atributo *Bilirubin*, mostrado na Figura abaixo.




Fig. 3: Associação do atributo *Bilirubina* e atributo *Status*, onde os pacientes vivos são representados pelas barras verdes, os pacientes falecidos pelas barras azuis e os pacientes transplantados pelas barras laranja.

Os atributos *Status* e *Bilirubina* parecem apresentar também uma correlação entre si. Como se pode observar na Figura 3, valores menores de bilirrubina parecem estar relacionados com uma menor probabilidade de morte ou necessidade de transplante. De forma contrária, valores superiores de bilirrubina parecem estar mais associados à probabilidade de morte, já que se observa um maior número de casos de morte com valores superiores deste atributo.

Os gráficos desenvolvidos para associação dos atributos *Edema* e *Ascites* e atributo *target Status* são bastante semelhantes, pelo que foram apresentados na mesma Figura.




Fig. 4: Associação dos atributos *Edema* e *Ascites*, respetivamente, e o atributo de *Stage*, onde os pacientes vivos são representados pelas barras verdes, os pacientes falecidos pelas barras azuis e os pacientes transplantados pelas barras vermelhas.

A presença de ascites vasculares e edema podem estar associadas à probabilidade de morte de doença hepática. Como se pode verificar, na figura acima, apenas apresentam ascites e edema doentes com uma probabilidade de morte muito elevada. Nos dois casos, no caso de ausência de ascites ou edema, existem todos os tipos de casos de sobrevivência, sobressaindo, no entanto, a sobrevivência sem necessidade de transplante. A análise dos gráficos desenvolvidos para os restantes atributos não foi conclusiva. Assim, as suas relações com o atributo *target* não trazem conclusões significativas sobre a sua influência na sobrevivência do doente com ou sem transplante.

Foram também analisados os pesos de cada um dos atributos de forma a analisar quais poderão ter um impacto mais significativo na previsão do modelo. Foi utilizada a técnica *weight by correlation* [8] para o efeito.




Fig. 5: Pesos dos atributos do *dataset*.

Como se observa na Figura 5, foram analisados os pesos de cada um dos atributos. Verificou-se que os maiores pesos estão associados a atributos como a *Bilirubin*, *Prothrombin* e *Age*, correspondendo a valores de 1.000, 0.980 e 0.850, respetivamente. É observável, também, que os atributos de menor peso são o *Drug*, *Cholesterol* e *Sex*, apresentando valores de 0.000, 0.236 e 0.246, respetivamente. As conclusões retiradas dos pesos dos atributos bem como das suas correlações com o atributo *target* serão importantes nas fases seguintes do processo de *Data Mining*.

4 Data Preparation

De modo a preparar os dados para a elaboração dos modelos, foi necessário, numa primeira instância, remover o atributo *ID*, por não apresentar informação relevante

para o estudo em questão. Em seguida, procedeu-se à seleção do atributo a prever, ou seja, o *target*, definindo para tal o atributo *Status*. Posteriormente, foi necessário tratar os valores em falta, visto que a quantidade destes era elevada. Porém, não foram removidos atributos, uma vez que os valores ausentes representam menos de 35% da totalidade dos dados de cada coluna.

Adicionalmente, foi averiguado que não existiam *outliers* nos dados em questão, sendo concluído que não seria necessário efetuar qualquer tratamento relativo a estes.

Por fim, verificou-se que os dados não se encontravam balanceados, podendo levar à ocorrência de enviesamento do modelo, ou seja, as previsões tenderem sempre mais para o valor da classe cuja presença fosse mais proeminente. Deste modo, para evitar essa situação, foi efetuado o balanceamento do dataset, recorrendo à técnica SMOTE (*Synthetic Minority Over-sampling Technique*) para efetuar *upsampling*, ou seja, criar exemplos sintéticos da classe minoritária. Aplicando estes passos, conseguiu-se garantir que os dados se encontrassem preparados para a aplicação de um modelo apropriado.

5 Modeling

Nesta secção, demonstrar-se-ão as técnicas de análise de correlação, regras de associação e desenvolvimento de modelos de previsão em Classificação.

5.0.1 Análise de Correlações entre atributos

De forma a procurar relações entre atributos numéricos, foi realizada a análise de correlação. Na Figura 6 encontram-se os resultados obtidos.

Attributes	N_Days	Age	Bilirubin	Cholesterol	Albumin	Copper	Alk_Phos	SGOT	Tryglicerides	Platelets	Prothrombin
N_Days	1	-0.126	-0.404	-0.115	0.431	-0.320	0.131	-0.198	-0.127	0.147	-0.111
Age	-0.126	1	0.002	-0.130	-0.182	0.054	-0.041	-0.131	0.019	-0.146	0.114
Bilirubin	-0.404	0.002	1	0.338	-0.314	0.405	0.104	0.392	0.371	-0.013	0.313
Cholesterol	-0.115	-0.130	0.338	1	-0.055	0.123	0.140	0.337	0.277	0.151	-0.025
Albumin	0.431	-0.182	-0.314	-0.055	1	-0.226	-0.087	-0.188	-0.081	0.156	-0.199
Copper	-0.320	0.054	0.405	0.123	-0.226	1	0.187	0.294	0.272	-0.054	0.185
Alk_Phos	0.131	-0.041	0.104	0.140	-0.087	0.187	1	0.112	0.169	0.121	0.076
SGOT	-0.198	-0.131	0.392	0.337	-0.188	0.294	0.112	1	0.119	-0.101	0.095
Tryglicerides	-0.127	0.019	0.371	0.277	-0.081	0.272	0.169	0.119	1	0.080	0.016
Platelets	0.147	-0.146	-0.013	0.151	0.156	-0.054	0.121	-0.101	0.080	1	-0.154
Prothrombin	-0.111	0.114	0.313	-0.025	-0.199	0.185	0.076	0.095	0.016	-0.154	1

Fig. 6: Análise das correlações entre atributos numéricos do *dataset*.

Conforme ilustrado na Figura 6, não existem relações suficientemente fortes entre os atributos que permitam tirar conclusões relevantes. Por sua vez, a presença de valores de correlação consideravelmente baixos sugere que a interdependência entre os atributos é limitada. Esta constatação ressalta a dificuldade em identificar padrões significativos a partir das relações existentes na matriz.

5.0.2 Regras de Associação

Na sequência da exploração das relações entre os atributos, foram introduzidas regras de associação para análise dos atributos nominais.

Para a análise dos resultados, são utilizadas métricas de avaliação como o suporte e a confiança [9]. Com efeito, regras de associação com elevado suporte e/ou confiança representam resultados significativos, visto que, sendo uma regra recorrente, esta pode representar informação real a partir da qual se formam associações viáveis. Os resultados obtidos encontram-se presentes na Tabela abaixo:

Table 3: Regras de Associação obtidas.

Premissas	Conclusão	Suporte	Confiança
Edema, Hepatomegaly	Ascites	0.325	0.986
Edema, Spiders	Ascites	0.471	0.985
Edema, Spiders, Hepatomegaly	Ascites	0.282	0.983
Spiders, Hepatomegaly	Ascites	0.299	0.969
Hepatomegaly	Ascites	0.352	0.967
Spiders	Ascites	0.505	0.950
Spiders, Hepatomegaly	Edema, Ascites	0.282	0.915

A partir da análise da Tabela 3, foram encontradas 7 regras de associação entre atributos. Assim, é possível ressaltar a associação de presença de *Spiders* e *Edemas* à presença de *Ascites*, com um suporte de 0.471 e uma confiança de 0.985. Desta forma, conclui-se que quando estão presentes *Spiders* e *Edemas*, é altamente provável também existir *Ascites*. Da mesma forma, é também possível associar a presença de *Edemas* e *Hepatomegaly* à presença de *Ascites*, com um suporte de 0.325 e uma confiança de 0.986. De facto, na secção de *Data Understanding*, os dados obtidos nos gráficos da Figura 4, permitem corroborar o sucedido, já que os atributos *Edemas* e *Ascites* apresentam a mesma distribuição.

5.0.3 Modelos de Data Mining para Classificação

Na secção de *Modeling* serão também explorados diferentes Modelos de *Data Mining* (DMM) usados para obtenção dos resultados.

Os DMM possuem a seguinte fórmula: DMM = { Abordagem (A), Cenários (C), Técnicas de Mineração de Dados (DMT), Métodos de Partição de Dados (SM), Abordagens de Dados (DA), *Target (TG)* }.

A abordagem escolhida consiste na Classificação, onde foram usadas 5 diferentes técnicas de DM: *k-Nearest Neighbors* (kNN), *Random Forest* (RF), *Árvores de Decisão* (DT), *Gradient Boosting* (GB) e *Naive Bayes* (NB). Estes algoritmos foram utilizados com as configurações padrão.

Da mesma forma, para cada técnica de DM foram testados 2 métodos de partição de dados: *Cross Validation* (10 folds) e *Holdout Sampling* (com 1/3 dos dados para teste). Os cenários considerados, a fim de avaliar quais atributos eram mais importantes para prever a sobrevivência em doentes com doença hepática, foram escolhidos tendo em

consideração a secção de *Data Understanding*, nomeadamente a análise dos pesos de cada um deles. Com efeito, os cenários podem ser definidos da seguinte forma:

- C1: {Todos os atributos};
- C2: {*NDays*, *Ascites*, *Edema*, *Spiders*, *Stage*, *Bilurribin*, *Status*};
- C3: {*Todos os atributos exceto Drug*, *Cholesterol* e *Sex*};
- C4: {*Bilirubin*, *Prothrombin*, *Ascites*, *Age*, *NDays*, *Edema*, *Copper*, *Status*}.

Uma vez que as classes no *target* não estavam balanceadas, foi necessário proceder ao balanceamento do mesmo, havendo, portanto, apenas uma abordagem de dados. Com efeito, é possível definir os Modelos de DMM como:

DMM = { { A_f = Classificação}, C_i = {C1, C2, C3, C4}, DMT_y = {*kNN*, *RF*, *DT*, *GB*, *NB*}, SM_c = {*Holdout Sampling*, *Cross Validation*}, DA_b = {*Com oversampling*}, TG_t = {*C* (questionado) ou *CL* (questionado para transplante) ou *D* (morte)} }

Assim, obtêm-se um total de 40 modelos diferentes para comparar e analisar.

6 Avaliação

Através dos cenários desenvolvidos anteriormente e das técnicas também mencionadas acima, foram testados todos os modelos possíveis com recurso ao software *RapidMiner*. As métricas de avaliação utilizadas para medir o desempenho e, consequentemente, comparar cada modelo entre si foram a *Accuracy*, Precisão e Sensibilidade. A *Accuracy* foi utilizada como métrica mais geral para avaliar a percentagem de casos que o modelo acerta corretamente [8].

Quanto à precisão, esta foi utilizada para avaliar a influência de falsos positivos do modelo, uma vez que, mede a percentagem de previsões positivas corretas em relação ao total de casos previstos como positivas pelo modelo [8]. Neste caso, esta métrica é importante na medida em que diminui a probabilidade de referenciar um doente para transplante ou possível morte desnecessariamente bem como a referência errada de um doente como sobrevivente sem tratamento.

Por outro lado, foi utilizada a sensibilidade que identifica todos os casos previstos corretamente como positivos no conjunto de dados [10]. A utilização da métrica de sensibilidade prende-se na avaliação da capacidade de o modelo identificar os indivíduos que na realidade têm necessidade de transplante, risco de morte ou a sobrevivência.

Para cada modelo foi desenvolvida a matriz de confusão, com as informações de verdadeiros positivos (TP), verdadeiros negativos (TN), falsos negativos (FN) e falsos positivos (FP) para cada classe do atributo *Status*. A partir destes dados foram então calculados os valores de *Accuracy*, Precisão (Prec) e Sensibilidade (Rec) para cada modelo.

Os 10 melhores resultados de desempenho, neste caso, utilizando um critério de *Accuracy* superior a 70% encontram-se na tabela 4, onde também se apresentam os valores de precisão e sensibilidade obtidos para cada modelo. Na tabela encontra-se também informação sobre o cenário, técnica, métodos de partição de dados e abordagem de dados utilizada.

Table 4: 10 melhores resultados de *Accuracy*, Precisão (Prec) e Sensibilidade (Rec) para cada classe dos modelos testados.

#	DMT	C	SM	DA	Acuracy	Rec D	Rec C	Rec CL	Prec D	Prec C	Prec CL
1	RF	C1	HS	oversampling	80	70,83	87,14	78,38	91,89	77,22	74,36
2	RF	C3	HS	oversampling	80	70,84	90	72,97	85	74,12	90
3	kNN	C1	CV	oversampling	76,5	33,33	59,68	100	61,11	78,72	77,78
4	RF	C3	CV	oversampling	76,23	68,94	86,64	66,4	77,62	72,56	84,69
5	RF	C1	CV	oversampling	75,85	65,84	85,78	70,4	77,94	72,1	83,02
6	GB	C3	CV	oversampling	74,5	61,49	83,19	72,2	75,57	73,38	75,81
7	GB	C1	CV	oversampling	72,55	60,87	80,17	73,6	71,01	73,23	73,02
8	GB	C3	HS	oversampling	72,26	58,33	82,86	70,27	73,68	72,5	70,27
9	GB	C1	HS	oversampling	71,61	56,25	75,71	83,78	77,14	74,65	63,27
10	NB	C1	CV	oversampling	70,46	54,04	78,02	77,6	75,65	70,16	66,9

A tabela apresentada acima não só permite tirar conclusões acerca dos melhores modelos a utilizar para previsão de casos de sobrevivência, transplante ou morte, mas também tirar conclusões acerca dos melhores cenários e técnicas de Data Mining a utilizar no dataset.

7 Discussão

Conforme apresentado na Tabela 4, é possível obter melhores resultados recorrendo ao modelo de *Random Forest* (RF), tendo-se, com este, atingido uma *accuracy* de 80% e uma sensibilidade de 87.14% para a classe C e precisão de 91.89% para a classe D. A sensibilidade e precisão das outras classes não são tão elevadas, mas, no geral, são melhores do que as dos outros modelos.

Verifica-se, ainda, que no caso 3, apesar do valor elevado de *accuracy*, os resultados de sensibilidade para as classes D e C foram consideravelmente inferiores à da classe CL, podendo tal ocorrência ser explicada pela existência de *overfitting*, resultante de registos repetidos, gerados aquando do processo de balanceamento dos dados efetuado inicialmente.

Adicionalmente, averiguou-se que os resultados dos cenários 1 e 3 são melhores do que para os restantes, sendo que a diferença entre estes reside somente nos atributos *Drug*, *Cholesterol* e *Sex*, ausentes no terceiro cenário. Tendo em conta que os resultados para ambos os cenários são muito semelhantes, conclui-se que estes atributos não terão elevada influência no resultado final. Tal conclusão suporta ainda o que foi referido anteriormente, relativamente aos pesos de cada atributo sobre o *target*.

Por fim, analisando o melhor resultado obtido e considerando as métricas relevantes neste estudo, chega-se à conclusão de que em média o modelo acerta em 80% dos casos que recebe para classificar. Relativamente ao caso de previsão da classe D, associada à morte do indivíduo, observa-se que o modelo apresenta uma elevada sensibilidade, sendo eficaz na identificação de casos reais de falecimento, porém a precisão é um pouco menor, refletindo-se na possibilidade de existência de falsos positivos. Neste caso, a obtenção de um falso positivo não seria crítica, caso tal não implique o cessamento da administração de tratamento e uma eventual reavaliação.

Em relação ao caso da previsão da necessidade e capacidade de submissão a transplante, o modelo tem um comportamento ligeiramente menos satisfatório, apresentando uma precisão relativamente boa, sendo que a maior parte dos doentes identificados como candidatos a transplante efetivamente o é. Contudo, o valor de sensibilidade é menor, sendo menos capaz de identificar candidatos a transplante à priori, o que poderá ser uma limitação, levando a que uma parte dos pacientes, apesar de mínima, não seja diagnosticado a tempo, ou de modo correto, para ser submetido a transplante. Neste caso, uma hipótese de melhoria seria procurar aumentar a sensibilidade, mesmo que tal implique uma redução da precisão, visto se tratar de um aspeto crítico onde a identificação de falsos positivos seria melhor do que a não identificação de todos dos verdadeiros positivos, podendo pôr em causa vidas. Ainda assim, pode-se destacar que o modelo tem uma performance geral bastante satisfatória.

8 Conclusão

Este processo de aprendizagem e extração de conhecimento permitiu a descoberta de regras de associação entre atributos e o desenvolvimento de modelos capazes de classificar casos de sobrevivência em doentes com cirrose através de dados clínicos presentes no *dataset cirrhosis*.

Este processo de *Data Mining* apresenta contribuições significativas que o destacam em relação a abordagens anteriores [8]. A nossa principal contribuição centra-se na construção de um modelo com capacidade de previsão de multi-classe, neste caso, sobrevivência, morte ou necessidade de transplante em doentes hepáticos, alcançando um desempenho notável de cerca de 80%.

A utilização deste tipo de modelos de *Data Mining* complementa a área da medicina constituindo uma ferramenta essencial, especialmente em contextos de diagnóstico precoce [11] [12]. A capacidade de extração de conhecimento, padrões e informações relevantes dos dados contribui significativamente para a área da saúde, proporcionando novas formas de diagnóstico e novas associações entre atributos promovendo a descoberta de fatores de risco e, no geral, um aumento na qualidade dos cuidados de saúde [13].

Ainda assim, existem aspetos passíveis de melhorias futuras, nomeadamente, a utilização de outras técnicas de *Data Mining*, o aumento dos dados fornecidos aos modelos e ainda a exploração da existência de atributos adicionais que possam ser incorporados ao modelo, como por exemplo, atributos relativos a comportamentos de risco. Esta análise de novos atributos é crucial para a tentativa de melhoria do desempenho dos modelos desenvolvidos, permitindo uma compreensão mais abrangente da doença em estudo.

Referências Bibliográficas

- [1] Wu, D., Jing, X., Zhang, H., Kong, X., Xie, Y., Huang, Z.: Data-driven approach to application programming interface documentation mining: A review. *WIREs Data Mining and Knowledge Discovery* **10** (2020) <https://doi.org/10.1002/widm.1369>

- [2] Dickson, G.P.F.T.F.L. E., Langworthy, A.: Cirrhosis Patient Survival Prediction. UCI Machine Learning Repository (2023). <https://doi.org/10.24432/C5R0>
- [3] Ferreira, D., Silva, S., Abelha, A., Machado, J.: Recommendation system using autoencoders. *Applied Sciences* **10**, 5510 (2020) <https://doi.org/10.3390/app10165510>
- [4] Wirth, R., Hipp, J.: Crisp-dm: Towards a standard process model for data mining. In: *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, vol. 1, pp. 29–39 (2000). Manchester
- [5] Schröer, C., Kruse, F., Gómez, J.M.: A systematic literature review on applying crisp-dm process model. *Procedia Computer Science* **181**, 526–534 (2021)
- [6] Christensen, E., Neuberger, J., Crowe, J., Altman, D.G., Popper, H., Portmann, B., Doniach, D., Ranek, L., Tygstrup, N., Williams, R.: Beneficial effect of azathioprine and prediction of prognosis in primary biliary cirrhosis: final results of an international trial. *Gastroenterology* **89**(5), 1084–1091 (1985)
- [7] Hanif, I., Khan, M.M.: Liver cirrhosis prediction using machine learning approaches. In: *2022 IEEE 13th Annual Ubiquitous Computing, Electronics Mobile Communication Conference (UEMCON)*, pp. 0028–0034 (2022). <https://doi.org/10.1109/UEMCON54665.2022.9965718>
- [8] Ferreira, D., Neto, C., Lopes, J., Duarte, J., Abelha, A., Machado, J.: Predicting the survival of primary biliary cholangitis patients. *Applied Sciences* **12**(16) (2022)
- [9] Gammermann, A.: Support vector machine learning algorithm and transduction. *Computational Statistics* **15**(1), 31–39 (2000)
- [10] Fonseca, F., Peixoto, H., Miranda, F., Machado, J., Abelha, A.: Step towards prediction of perineal tear. *Procedia Computer Science* **113**, 565–570 (2017) <https://doi.org/10.1016/j.procs.2017.08.284> . The 8th International Conference on Emerging Ubiquitous Systems and Pervasive Networks (EUSPN 2017) / The 7th International Conference on Current and Future Trends of Information and Communication Technologies in Healthcare (ICTH-2017) / Affiliated Workshops
- [11] Aslandogan, Y.A., Mahajani, G.A.: Evidence combination in medical data mining. In: *International Conference on Information Technology: Coding and Computing*, 2004. *Proceedings. ITCC 2004.*, vol. 2, pp. 465–469 (2004). IEEE
- [12] Makkena, K., Natarajan, K.: Classification algorithms for liver epidemic identification. *EAI Endorsed Transactions on Pervasive Health and Technology* **9** (2023) <https://doi.org/10.4108/eetpht.9.4379>
- [13] Neto, C., Peixoto, H., Abelha, V., Abelha, A., Machado, J.: Knowledge discovery

from surgical waiting lists. *Procedia Computer Science* **121**, 1104–1111 (2017)
<https://doi.org/10.1016/j.procs.2017.11.141> . CENTERIS 2017 - International
Conference on ENTERprise Information Systems / ProjMAN 2017 - International
Conference on Project MANagement / HCist 2017 - International Conference on
Health and Social Care Information Systems and Technologies