

Distinção de exames de Ressonância Magnética sintéticos e reais a partir de dados radiómicos

Imagiologia

Mestrado em Informática Médica

Braga, maio 2024

Docente: Vítor Alves

Madalena Passos, pg54023;

Mariana Almeida, pg54062;

Mariana Ribeiro, pg54061;

Mónica Martins, a95918.

Introdução

O avanço tecnológico na área da inteligência artificial e do *Machine Learning* (ML) tem revolucionado inúmeras áreas, sendo a da saúde uma das mais impactadas. O presente trabalho tem como objetivo aplicar técnicas de *Machine Learning* para desenvolver um modelo capaz de classificar exames de Ressonância Magnética como reais ou sintéticos. Esse desafio não apenas envolve a criação de um modelo eficiente, mas também a interpretação dos resultados obtidos, com o objetivo de identificar as características radiômicas, *features*, mais relevantes para a classificação.

Para este projeto, foram fornecidos seis *datasets* referentes a exames de ressonância magnética, contendo três *datasets* de dados reais e três de dados sintéticos. Esses conjuntos de dados incluem diferentes máscaras: máscara de tumor, máscara de cérebro e uma combinação de ambas. Esta combinação permite uma análise abrangente das características que diferenciam exames reais de sintéticos.

Foram seguidas várias etapas, nomeadamente a exploração, análise e preparação dos *datasets*, a implementação dos modelos de *Machine Learning*, e a análise crítica dos resultados. Este trabalho permite a exploração do desenvolvimento de modelos de *Machine Learning*, bem como capacidades críticas na interpretação dos resultados e na identificação de características relevantes.

Objetivos do Trabalho

O principal objetivo deste trabalho foi desenvolver e otimizar um modelo de *Machine Learning* capaz de distinguir exames RM reais e sintéticos a partir de *features radiomics*. Este processo revelou-se útil para identificar os casos mais difíceis de prever de entre o conjunto de teste e ainda as *features radiomics* mais relevantes para essa distinção. Os resultados obtidos serão utilizados para posterior criação de uma função com as 5 *features* mais importantes de forma a ser melhorado o processo de geração de dados sintéticos, bem como o processo de discriminação entre dados sintéticos e reais.

Para atingir os objetivos propostos, foi seguida a seguinte metodologia ao longo do projeto:

- Preparação do *dataset*;
- Tratamento do *dataset*;
- Desenvolvimento do modelo de *Machine Learning*;
- Obtenção dos resultados e análise crítica dos mesmos.

Descrição do Processo

Para implementar as etapas descritas acima, foi necessário criar três *notebooks Python* (NB) distintos. Cada *notebook* foi especificamente dedicado a uma das diferentes máscaras fornecidas: máscara combinada (tumor e cérebro), máscara de tumor e máscara de cérebro, *all_mask.ipynb*, *tumor_mask.ipynb* e *brain_mask.ipynb*, respetivamente.

Embora a abordagem geral tenha sido consistente, cada máscara apresentou características únicas que exigiram tratamentos específicos. Nas seções seguintes, descreve-se detalhadamente o processo, destacando as ligeiras diferenças encontradas em cada *notebook*, bem como as particularidades dos diferentes *datasets* utilizados.

Preparação dos Dados

A preparação dos dados neste projeto compreende diversas etapas cruciais para assegurar que os dados estejam adequadamente preparados para a modelação.

Deste modo, foram inicialmente estabelecidas *labels* 0 e 1 correspondentes à natureza das imagens, sintéticas ou reais, respetivamente, de modo a ser possível averiguar o sucesso dos modelos implementados.

Adicionalmente, os pares de *datasets*, real e sintético (relativos à mesma máscara), foram fundidos resultando em 3 *datasets* com dados reais e sintéticos da máscara total, máscara do cérebro e tumor, *WholeScan_Mask*, *Brain_Mask*, *Tumor_Mask*, respetivamente. Posteriormente, os seus dados foram baralhados recorrendo à *seed* especificada em *random_state*, impedindo que qualquer ordem presente nos dados influenciasse o treino e permitindo a reprodutibilidade do processo de *shuffle*.

Assim, este processo de preparação dos dados garante que os modelos de *Machine Learning* aplicados posteriormente sejam treinados de forma justa e eficiente, sendo, no entanto, necessário o tratamento dos dados em maior detalhe.

Tratamento dos Dados

O tratamento de dados foi uma etapa fundamental antes de proceder para a fase de modelação. Assim, o tratamento efetuado garantiu a qualidade e a integridade dos dados utilizados no treino e teste do modelo, sendo que o mesmo foi realizado nos 3 *notebooks* criados. O tratamento foi o seguinte:

Contagem de Valores Nulos:

- **Nb All_mask** foi verificado que não existem valores nulos no *csv* gerado, não sendo necessário realizar nenhuma eliminação.
- **Nb Brain_mask**: foram identificadas 4 colunas com valores nulos, sendo que foram removidas para garantir a integridade dos dados.
- **Nb Tumor_mask**: não foram encontrados valores nulos, não sendo necessário realizar nenhuma eliminação.

Eliminação de Colunas Não Numéricas:

- As colunas não numéricas presentes em cada ficheiro foram eliminadas, uma vez que não eram utilizadas no modelo desenvolvido.

Normalização dos Dados:

- As colunas presentes em cada ficheiro foram normalizadas através da função *MinMaxScaler*, para assegurar que todas as *features* estavam contidas no mesmo intervalo.

Divisão dos Dados - Holdout Estratificado:

- Para garantir uma boa representatividade das classes tanto no conjunto de treino quanto no de teste, foi utilizada a técnica de *Holdout* estratificado, dividindo os dados em 70% para treino e 30% para teste. Esta técnica garante a mesma proporção de exames reais e sintéticos em ambos os conjuntos.

Preparação do Dataset para o Treino:

- Antes de treinar o modelo, foi realizada a eliminação do *label* dos conjuntos de treino e teste. Esta etapa foi necessária para assegurar que o algoritmo não utilize essa informação durante o processo de aprendizagem.

Verificação do Balanceamento dos Dados:

- Foi verificado o balanceamento dos dados para garantir que a proporção de exames reais e sintéticos estivesse correta e equilibrada entre os dados de treino e teste.

Modelos e Avaliação

Na etapa de desenvolvimento do modelo de ML, utilizou-se o modelo *Random Forest*, definindo *n_estimators*=100. O modelo foi inicialmente treinado com todas as *features* (colunas) e, em

seguida, avaliou-se a importância das mesmas utilizando a métrica *feature_importance*, selecionando aquelas com importância maior que 0.

As *features* relevantes foram então selecionadas e o modelo foi retreinado com os mesmos hiperparâmetros. Em cada etapa deste processo iterativo, os modelos foram avaliados para alcançar altos valores de *accuracy*.

No *notebook WholeScan_mask.ipynb*, nas últimas duas etapas de treino, o número de *features* dado ao modelo foi reduzido para 5 e 1, pois essas foram identificadas como as que possuem maior valor de *feature importance*. No *notebook brain.ipynb*, nas últimas duas etapas, o número de *features* foi reduzido para 5, 3 e 1, seguindo a mesma lógica de importância das *features*. No *notebook tumor.ipynb*, o número de *features* foi reduzido para 50, 10, 5 e 1 nas últimas etapas, também com base na *feature importance*.

Os modelos finais, nos quais se obteve melhor *accuracy*, foram definidos com 5 *features* para o *NB WholeScan_mask* e *NB brain_mask* e com 10 *features* para o *NB tumor_mask*. Posteriormente, utilizou-se a função *predict_proba*, que retorna a probabilidade de classificação do exame como real ou sintético.

Com as 5 ou 10 *features*, dependendo do NB, resultantes do modelo *Random Forest*, também foi utilizado o modelo *Logistic Regression*, de forma a averiguar se este apresentaria melhores resultados na classificação. Aplicou-se igualmente a função *predict_proba* de forma a obter as probabilidades da classificação.

Por fim, avaliou-se a performance dos modelos desenvolvidos:

	Accuracy (%) Random Forest	Accuracy (%) Logistic Regression
<i>WholeScan (5 features)</i>	96,66	96,66
<i>Cérebro (5 features)</i>	100	96,66
<i>Tumor (10 features)</i>	90	86,66

Para o melhor modelo de cada NB, mais precisamente, os modelos *Random Forest* com 5 *features* para o *NB WholeScan_mask* e *NB brain_mask* e 10 *features* para o *NB tumor_mask*, apresentou-se uma coluna com a previsão probabilística das classes e o valor real do exame, a fim de avaliar quais os casos mais difíceis de prever pelos modelos.

É importante destacar que a técnica *XGBoost* também foi testada. No entanto, esta não se mostrou adequada para o problema de classificação, uma vez que não conseguiu convergir durante o processo de treino.

Resultados

Durante a análise das previsões do modelo, observou-se que existiam alguns casos mais difíceis de prever em cada um dos *notebooks*.

Desta forma, em cada *notebook* foi utilizado o modelo com melhor *accuracy* para a análise destes casos.

No que diz respeito à máscara do tumor, alguns exames foram previstos incorretamente, havendo situações em que o modelo previa que o exame era real, mas na realidade era sintético. Admitindo que os exames com maior dificuldade de previsão encontram-se entre as probabilidades 0,35 e 0,65, foram encontrados os seguintes casos:

Tabela 1- Casos com dificuldade de previsão na máscara do tumor.

Volume	Probabilidade	Valor Previsto	Valor real	Previsão
synt_BraTS-GLI 000 62 00 0_0000. nii.gz	[0.38 0.62]	1.0 (real)	0.0 (sintético)	Incorreta
BraTS-GLI 00009 001_0000 .nii.gz	[0.59 0.41]	0.0 (sintético)	1.0 (real)	Incorreta
BraTS-GLI-00022-000_0000.nii.gz	[0.47 0.53]	1.0 (real)	1.0 (real)	Correta
synt_BraTS-GLI-00000-000_0000.nii.gz	[0.55 0.45]	0.0 (sintético)	0.0 (sintético)	Correta
BraTS-GLI-00022-001_0000.nii.gz	[0.42 0.58]	1.0 (real)	1.0 (real)	Correta
synt_BraTS-GLI-00061-000_0000.nii.gz	[0.57 0.43]	0.0 (sintético)	0.0 (sintético)	Correta
BraTS-GLI-00011-000_0000.nii.gz	[0.61 0.39]	0.0 (sintético)	1.0 (real)	Incorreta

Relativamente à máscara do cérebro, foi encontrado apenas 1 exame em que o modelo mostrou alguma dificuldade em prever, embora o esteja a prever corretamente. Este exame correspondeu ao volume *BraTS-GLI-00048-001_0000.nii.gz* com uma probabilidade de 0,60 a prever que o exame era sintético.

Quanto à máscara *whole*, verificaram-se os seguintes casos:

Tabela 2-Casos com dificuldade de previsão na máscara whole.

Volume	Probabilidade	Valor Previsto	Valor real	Previsão
synt_BraTS-GLI-00061000_0000.nii.gz	[0.38 0.62]	1.0 (real)	0.0 (sintético)	Incorreta
BraTS-GLI-00053-000_0000.nii.gz	[0.34 0.66]	1.0 (real)	1.0 (real)	Correta

Quanto às *features* mais importantes em cada máscara, foi concluído o seguinte:

Na máscara do cérebro, foi obtida uma *accuracy* de 100%, incluindo apenas as seguintes *features*:

- **wavelet-HHH_firstorder_Kurtosis:** Esta *feature* mede a acuidade da distribuição dos valores dos *pixels*. Deste modo, um valor alto desta *feature* indica uma distribuição com picos agudos. No entanto, um valor baixo representa uma distribuição mais plana;
- **wavelet-HHH_glcmm_Idmn:** A matriz “GLCM” refere-se à matriz de co-ocorrência dos níveis de cinza. Por outro lado, o campo “Idmn” permite medir a homogeneidade de uma imagem (inversa da diferença média normalizada);
- **wavelet-HHH_glcmm_Idn:** Esta *feature* também permite medir a homogeneidade de uma imagem, no entanto, calculada de forma diferente (inverso da diferença normalizada);
- **wavelet-LHH_firstorder_Skewness:** Mede a assimetria da distribuição dos valores de cinza;
- **original_firstorder_Minimum:** É o valor mínimo existente na imagem, que se refere ao pixel mais escuro.

Por outro lado, na máscara do tumor, o modelo com melhor *accuracy* foi um modelo Random Forest com 10 *features*, com uma *accuracy* de 90%. As 5 *features* mais importantes deste modelo são as seguintes:

- **wavelet-HHH_glcmm_Imc1:** Esta característica deriva da matriz de co-ocorrência e mede a complexidade da textura da imagem. Valores mais altos desta *feature* indicam uma maior complexidade e, por consequência, menos homogeneidade da textura;
- **wavelet-HHH_glcmm_Imc2:** De forma diferente, esta *feature* mede também a complexidade da textura;
- **original_firstorder_Minimum:** Valor mínimo da imagem;
- **wavelet-HHH_glcmm_Correlation:** Mede a relação linear entre os valores de *pixels* na matriz de co-ocorrência. Deste modo, valores altos indicam que a intensidade de um *pixel* pode prever-se pela intensidade dos *pixels* vizinhos;
- **wavelet-HLH_firstorder_Kurtosis:** Novamente, a medida da curtose mostrou-se uma *feature* importante para avaliar a distinção entre os exames sintéticos e reais. No entanto, desta vez, esta *feature* revelou-se importante na decomposição wavelet HLH.

Por fim, no caso da máscara que incluía tanto o cérebro como o tumor, foi obtido um modelo com *accuracy* de 96,7%, com apenas 5 *features*:

- **wavelet-HHL_gldm_DependenceEntropy:** Esta *feature* permite avaliar a entropia dos valores dos pixels. Um maior valor desta *feature* indica uma maior desordem na textura;
- **wavelet-HHH_gldm_DependenceNonUniformityNormalized:** Mede a uniformidade dos valores de dependência, de forma normalizada. Deste modo, valores altos indicam uma textura heterogênea;
- **wavelet-HLH_gldm_Idmn:** Como explicado anteriormente, esta *feature* também é responsável por medir a homogeneidade da textura;
- **wavelet-HLL_firstorder_Mean:** Refere-se à intensidade média da imagem;
- **wavelet-HHL_gldm_LongRunEmphasis:** Avalia a existência de longas sequências de *pixels* com a mesma intensidade. Assim, valores altos indicam a existência destas sequências e, conseqüentemente, uma textura mais uniforme.

De forma a comprovar a influência das *features* mais importantes de cada NB no processo de classificação, visualizou-se a sua distribuição nos *datasets* reais e sintéticos, respetivamente. A escolha destas *features* baseou-se no valor mais alto de *feature_importance* retornadas dos modelos de melhor *accuracy*. Para os *dataset brain_mask*, *tumor_mask*, *WholeScan_mask* apresenta-se a distribuição das *features* *wavelet-HHH_firstorder_Kurtosis*, *original_firstorder_Minimum* e *wavelet-HHL_gldm_LongRunEmphasis*, respetivamente.




Figura 1 - Visualização da distribuição da *feature* mais importante no *dataset WholeScan_mask*




Figura 2 - Visualização da distribuição da feature mais importante no dataset *brain_mask*




Figura 3 - Visualização da distribuição da feature mais importante no dataset *tumor_mask*

Como evidenciado pela análise dos três gráficos apresentados, a distinção entre as distribuições dos dados reais e sintéticos é claramente perceptível. Portanto, é justificável que o modelo tenha atribuído uma elevada importância a essas *features*.

Conclusão

Através da utilização de modelos de classificação como *Random Forest*, *XGBoost* e Regressão Logística, foi possível alcançar resultados satisfatórios. Em particular, os modelos de *Random Forest* demonstraram um desempenho excepcional, atingindo uma precisão superior a 90% em todas as máscaras de dados avaliadas, quando treinados com informação de 5 ou 10 *features* importantes. Estes resultados indicam que os nossos modelos são eficazes na distinção entre exames reais e sintéticos.

Durante o processo de análise crítica dos resultados, identificaram-se os exames que o modelo apresentou mais dificuldade em classificar. Esta análise permitiu-nos compreender melhor as limitações do modelo e os aspetos que poderiam ser aprimorados em futuras iterações.

Além disso, uma parte fundamental do nosso trabalho foi a interpretação do modelo desenvolvido. Conseguiu-se identificar através dos modelos e da função *feature_importance*, as características radiômicas mais relevantes para a classificação, fornecendo *insights* valiosos sobre os fatores que influenciam a distinção entre exames reais e sintéticos. Essa compreensão é fundamental não só para melhorar futuros modelos, mas também para potencial aplicação prática na área da saúde, nomeadamente na área de geração de dados sintéticos.

De um modo geral, verificou-se que a máscara do cérebro foi aquela que se mostrou mais eficaz para a distinção entre exames sintéticos e reais, tendo sido esta a única máscara que, com 5 *features*, alcançou os 100% de precisão. No que diz respeito às *features*, verificou-se que algumas métricas de primeira ordem (como a média e o mínimo de valores de cinzento) e características relacionadas com a textura foram as mais importantes para a classificação.

Para aprimorar o trabalho desenvolvido e os valores de precisão obtidos, seria fundamental incluir mais dados para treinar os modelos. Para além disso, poderiam ser aplicados outros algoritmos de *Machine Learning* ou a exploração mais profunda dos hiper-parâmetros dos modelos utilizados.