



Inteligência Artificial

Machine Learning

Universidade do Minho

Inteligência Artificial em Engenharia Biomédica

1º Semestre – 22/23

5 de janeiro de 2023

Mariana Ribeiro, A9496;

Mariana Almeida, A97380;

Raquel Lima, A97590;

Marta Ferreira, A95978.

Resumo

Este trabalho foi desenvolvido no âmbito da unidade curricular de Inteligência Artificial (IA) em Engenharia Biomédica do 3.º ano do curso da licenciatura em Engenharia Biomédica. O seu objetivo centra-se no desenvolvimento de um sistema de aprendizagem automática (Machine Learning - ML) que permitisse o diagnóstico da existência ou não de doença cardíaca em pacientes.

Com base num *dataset* com o histórico de informações de vários hospitais em várias cidades mundiais, foi utilizada a plataforma KNIME para a criação de modelos de classificação de forma a prever se está associada uma doença ou não a um doente. Neste sentido, foi criado um pipeline de ML usando a plataforma e, após uma análise estatística prévia do conjunto de dados e algum pré-processamento e tratamento de dados, foram criados quatro modelos usando os algoritmos Árvores de Decisão, Random Forest, Gradient Boosting e Redes Neurais Artificiais.

Posteriormente, foram analisadas as várias métricas associadas ao desempenho dos modelos. Perante os resultados obtidos foi selecionado o modelo de classificação com melhor desempenho.

Como resultado deste trabalho, salienta-se além das aprendizagens associadas ao processo de análise de dados e criação de modelos de classificação, a utilização de plataformas de ML.

Tabela de conteúdos

Resumo.....	2
1.Introdução	8
2. Preliminares.....	9
2.1 Inteligência Artificial e Machine Learning	9
2.1.1 Aprendizagem supervisionada	9
2.1.2 Aprendizagem não supervisionada.....	13
2.1.3 Aprendizagem por reforço	14
2.2 Análise estatística e exploração de dados.....	14
2.3 Machine Learning Pipeline	16
2.4 Métricas de avaliação do modelo	17
2.5 Plataforma KNIME	19
3. Desenvolvimento do Sistema de Aprendizagem Automática	19
3.1 Pipeline.....	20
3.2. Carregamento de dados	20
3.3 Exploração e Análise de dados.....	21
3.3.1 Dataset Cleveland.....	22
3.3.2 Dataset LongBeach	25
3.3.3 Dataset Hungarian.....	27
3.3.4 Dataset Switzerland.....	30
3.4 Preparação e Transformação dos dados	33
3.4.1 Dataset Cleveland.....	33
3.4.2 Dataset Long Beach	35
3.4.3 Dataset Hungarian.....	37
3.4.4 Dataset Switzerland.....	39
3.5 Partição de dados e Criação dos Modelos.....	42
3.5.1 Partição de dados.....	42
3.5.2 Árvores de decisão	43
3.5.3 Random Forest	44
3.5.4 Gradient Boost	45
3.5.5 Redes Neurais Artificiais	47
3.6 Avaliação do desempenho dos modelos.....	48
3.6.1 Árvores de decisão	48
3.6.2 Random Forest	51
3.6.3 Gradient Boosting	53

3.6.4 Redes Neurais Artificiais	55
3.6.5 Escolha do Modelo.....	57
4. Conclusão.....	58
5 Referências.....	59
6.Anexos.....	60

Tabela de figuras

Figura 1-Algoritmo Árvore de Decisão.	10
Figura 2-Algoritmo Random Forest	11
Figura 3-Arquitetura do algoritmo Gradient Boosting	12
Figura 4-Rede Neuronal Artificial.	13
Figura 5- Histograma e distribuição Normal.....	15
Figura 6-Exemplo de Box Plot e Outliers	15
Figura 7-Machine Learning Pipeline	16
Figura 8-Matriz de Confusão	17
Figura 9- Curva ROC.	18
Figura 10-Nodo CSV Reader.	20
Figura 11-dataset- Cleveland.	21
Figura 12-Nodos Data Explorer, Statistics, Linear Correlation e Box Plot utilizados para a Exploração de dados.	21
Figura 13-Fluxo utilizado para a Exploração de Dados.	22
Figura 14-Informação Retirada do nodo Data Explorer no Dataset Cleveland.....	22
Figura 15-Informação retirada do nodo Statistics no Dataset Cleveland.	23
Figura 16-Boxplot do Dataset Cleveland.	24
Figura 17-Matriz de Cores sobre a Correlação do Dataset Cleveland.	24
Figura 18-Matriz de Correlação do Dataset Cleveland.	24
Figura 19-Informação retirada do nodo Data Explorer no Dataset LongBeach.....	25
Figura 20- Informação retirada do nodo Statistics no Dataset LongBeach.....	26
Figura 21-Boxplot e outliers do Dataset LongBeach.	26
Figura 22-Boxplot do Dataset LongBeach.....	27
Figura 23-Matriz de Correlação do Dataset LongBeach.....	27
Figura 24- Matriz de Correlação a cores do Dataset LongBeach.....	27
Figura 25-Informação retirado do nodo Data Explorer no Dataset Hungarian.	27
Figura 26-Informação retirada do nodo Data Explorer no Dataset Hungarian.	28
Figura 27-Informação retirada do nodo Statistics do Dataset Hungarian.	29
Figura 28- Boxplot obtido e outliers do Dataset Hungarian.....	29
Figura 29-Matriz Correlação do Data Set Hungarian.	30
Figura 30-Matriz de Correlação a cores do Dataset Hungarian.	30
Figura 31-Informação retirada do nodo Data Explorer no Dataset Switzerland.	30
Figura 32- Informação retirada do nodo Statistics no Dataset Switzerland.	31
Figura 33- Boxplot e outliers obtidos para o Dataset Switzerland.....	32
Figura 34- Matriz de Correlação do Dataset Switzerland.	32

Figura 35- Matriz de Correlação a cores do Dataset Switzerland.	32
Figura 36- Nodos Duplicate Row Filter, Numeric Outliers, Missing Values, Number To String, Rule Engine utilizados no tratamento dos dados.....	33
Figura 37- Nodos implementados para o tratamento de dados no dataset Cleveland.	34
Figura 38- Configuração do nodo Numeric Outliers no Dataset Cleveland.	34
Figura 39 – Configuração do nodo Missing value no Dataset Cleveland.	35
Figura 40- Configuração do nodo Number to String.	35
Figura 41 – Configuração do nodo Rule Engine no Dataset Cleveland.....	35
Figura 42-Nodos implementados para o tratamento de dados no dataset LongBeach.	36
Figura 43 – Configuração do nodo Column Filter no Dataset Long Beach.	36
Figura 44 – Configuração do nodo Number to String no Dataset LongBeach.....	36
Figura 45 – Configuração do nodo Rule Engine no Dataset LongBeach.....	37
Figura 46-Nodos implementados para o tratamento de dados no dataset Hungarian.	37
Figura 47 – Configuração do nodo Numeric Outliers no Dataset Hungarian.	37
Figura 48 – Configuração do nodo Column Filter no Dataset Hungarian	38
Figura 49 – Configuração do nodo Number to String no Dataset Hungarian	38
Figura 50 – Configuração do nodo Rule Engine no Dataset Hungarian	38
Figura 51-Nodos implementados para o tratamento de dados no dataset Switzerland	39
Figura 52 – Configuração do nodo Numeric Outliers no Dataset Switzerland.	39
Figura 53 – Configuração do nodo Column Filter no Dataset Switzerland.	40
Figura 54 – Configuração do nodo Number to String no Dataset Switzerland.....	40
Figura 55- Configuração do nodo Rule Engine no Dataset Switzerland.....	40
Figura 56 – Configuração do nodo Concatenate.....	41
Figura 57-Nodo Column Expressions e a sua configuração.	41
Figura 58-Fluxo criado para preparação de dados do dataset total.	42
Figura 59-Nodo Normalizer.....	42
Figura 60- Nodo Partiotioning e a sua configuração.....	43
Figura 61- Nodo Decision Tree Learner e a sua configuração.....	44
Figura 62- Nodo Decision Tree Predictor.	44
Figura 63- Modelo Decision Tree Learner.....	44
Figura 64- Nodo do Random Forest Learner	45
Figura 65- Nodo Random Forest Predictor.	45
Figura 66- Fluxo do Modelo Random Forest Learner.	45
Figura 67- Nodo Gradient Boosted Learner.....	46
Figura 68- Configuração do nodo Gradient Boosted Trees Learner.	46
Figura 69- Nodo Gradient Boosted Tree Predicted.....	46
Figura 70- Modelo Gradient Boosting.	46

Figura 71- Nodo RProp MLP Learner e a sua configuração.....	47
Figura 72- Nodo MultiLayerPerceptron Predictor.	48
Figura 73- Modelo Redes Neurais.	48
Figura 74- Nodos Scorer (Java Script) e ROC Curve utilizados na avaliação dos modelos.	48
Figura 75- Matriz de Confusão do Modelo Árvores de Decisão.....	49
Figura 76- Matriz de estatísticas do modelo Árvores de Decisão.	50
Figura 77- Curvas ROC do modelo Árvores de Decisão.	51
Figura 78- Matriz de Confusão do Modelo Random Forest.....	51
Figura 79- Matriz de estatísticas do modelo Random Forest.	52
Figura 80- Curvas ROC do modelo Random Forest.	52
Figura 81- Matriz de confusão do modelo de Gradient Boosting.	53
Figura 82- Matriz de estatísticas do modelo Gradient Boosting	53
Figura 83 – Curva ROC do modelo Gradient Boosted.	54
Figura 84 – Matriz de confusão do modelo de Redes Neurais.....	55
Figura 85- Matriz de estatísticas do modelo Redes Neurais.	55
Figura 86-Curvas ROC do modelo de Redes Neurais.....	56
Figura 87- Pipeline criado para o desenvolvimento de um modelo de Árvores de Decisão.	60

Índice de Tabelas

Tabela 1 – Comparação das métricas de avaliação dos modelos criados.....	57
Tabela A- Testes nos diferentes modelos para substituir missing-values.	60

1.Introdução

No âmbito da unidade curricular de Inteligência Artificial em Engenharia Biomédica, o objetivo do trabalho correspondeu à exploração de dados e ao desenvolvimento de um sistema de aprendizagem automática (modelo de classificação/previsão) que permitisse de certa forma, prever a existência ou não de doença cardíaca em doentes, tendo como base a informação contida em vários *datasets* fornecidos. Seguindo uma abordagem geral do processo de criação de modelos em IA/ML, foi usada a plataforma KNIME¹ explorando vários algoritmos e feita a análise do seu desempenho.

Neste contexto, este relatório apresenta o trabalho desenvolvido estando estruturado da seguinte forma. Inicialmente, são apresentados os conceitos teóricos base associados à temática, como uma breve abordagem à Inteligência Artificial e Machine Learning, aos tipos de Aprendizagem Automática, ao processo de análise estatística e exploração de dados, ao pipeline de ML, às métricas de avaliação do modelo, assim como a descrição da plataforma KNIME.

De seguida, descreve-se como foi feita a análise das informações dadas e o tipo de conclusão retirada dessa exploração dos dados, que será a base das decisões tomadas no processamento dos dados antes de serem dados aos modelos. Assim, a seguir, explica-se que tipo de transformações foram feitas aos dados. Posteriormente, os dados são divididos em casos de treino e casos de teste e, por fim, serão desenvolvidos os modelos.

Posteriormente, no processo de desenvolvimento criaram-se quatro modelos com diferentes abordagens, nomeadamente, através do método das Árvores de Decisão, Random Forest e Gradient Boosting e, ainda, das Redes Neurais, sendo analisado os seus desempenhos.

No final apresenta-se as conclusões deste trabalho, as referências bibliográficas utilizadas e na secção dos anexos, apresenta-se informação complementar associada ao trabalho.

¹ Plataforma KNIME: <https://www.knime.com/knime-analytics-platform>

2. Preliminares

2.1 Inteligência Artificial e Machine Learning

A **Inteligência Artificial** (IA) [1] é amplamente conhecida como a criação de sistemas computacionais (programas informáticos ou modelos) baseados nos seres racionais (humanos ou animais) para tarefas de classificação, previsão, aglomeração (clustering), associação ou otimização, baseado em casos e descoberta de padrões nos dados.

Os algoritmos de IA são baseados em paradigmas ou abordagens como por exemplo o paradigma estatístico, simbólico (Árvores de Decisão e Representação do Conhecimento e Métodos de Raciocínio), conexionista (Redes Neurais Artificiais), evolutivo (Algoritmos Genéticos) ou ainda Baseado em Casos.

Estes sistemas tem como objetivo final serem instalados em máquinas (computadores) que permitam de certa forma, simular o comportamento dos seres racionais, e de forma automática e mais eficiente auxiliarem em processos de decisão.

Por outro lado, o conceito de **Aprendizagem Máquina** (Machine Learning) [1] corresponde a um processo associado à aprendizagem dos seres racionais que se baseiam em informação, sendo tipicamente caracterizada pela aprendizagem supervisionada para processos de classificação/previsão, aprendizagem não supervisionada para processos de aglomeração (clustering) ou aprendizagem por reforço ou semi-supervisionada que permite melhorar a eficiência das anteriores no processo de aprendizagem. Com base na informação histórica, a abordagem supervisionada centra-se na criação de modelos de classificação que permitem ser usados para tarefas de previsão. Neste sentido, nas últimas décadas, utilizando algoritmos de IA e abordagens de ML tem-se vindo a demonstrar com grande eficiência a criação de modelos de classificação e de previsão, ou mesmo de descoberta de padrões em contexto de previsão de problemas de doenças. De seguida descreve-se com mais algum detalhe os diferentes tipos de aprendizagem máquina.

2.1.1 Aprendizagem supervisionada

A aprendizagem supervisionada caracteriza-se por ser um paradigma/abordagem que se baseia em informação histórica catalogada (ex. se um paciente tem doença ou não). Com base na informação e a catalogação de um atributo classe/target, é criado um modelo. Neste processo, com a informação (dataset) é dividida em casos de treino do modelo e casos de teste. Os casos de

treino, casos que se usam para aprender, contêm informação sobre os resultados pretendidos. Desta forma é possível estabelecer uma relação entre os valores pretendidos e os valores produzidos pelo sistema.

Este tipo de aprendizagem subdivide-se em dois tipos de categorias: a classificação e regressão. Tipicamente, os problemas de classificação são associados a problemas de respostas qualitativas e têm como objetivo a identificação da classe a que pertence a amostra do problema. Por sua vez, os problemas de regressão são associados a problemas de respostas quantitativas, tendo como principal objetivo a previsão de um valor numérico.

Existem diversos algoritmos para a construção do modelo, sendo que neste trabalho irão ser utilizados os algoritmos de Árvore de Decisão, e ainda Random Forest e Gradient Boosting, e o algoritmo das Redes Neuronais Artificiais.

Algoritmo árvore de decisão

O algoritmo de árvore de decisão [2] pertence aos algoritmos de aprendizagem supervisionada, tanto de classificação como de regressão. Uma árvore de decisão pode ser vista como um grafo hierarquizado em que cada ramo representa a seleção entre um conjunto de alternativas, cada folha representa uma decisão e cada nodo interno testa um atributo.

A construção do modelo baseado neste algoritmo, desenvolve-se a partir da observação de exemplos, generalização e criação do modelo, apresentação do problema e obtenção de uma previsão.

Primeiramente, para se poder começar o processo, tem de se selecionar o nodo correspondente ao atributo “raiz”. Para tal, é necessário conhecer o conceito de entropia. A entropia é definida como a subtração do logaritmo da proporção de exemplos positivos ao logaritmo da proporção de exemplos negativos. O atributo com maior redução de entropia será a melhor escolha para ser nodo, de modo a reduzir a profundidade da árvore. Desta forma, o atributo que apresente maior ganho de informação será o atributo selecionado para a raiz da árvore de decisão. De seguida, verifica-se quais os valores possíveis desse atributo, sendo que correspondem ao número de ramos que surgirão da raiz. A seguir, prossegue-se novamente ao cálculo das entropias para os restantes dados, alcançando-se por fim uma árvore de decisão. Na figura 1 ilustra-se um exemplo da estrutura de uma árvore de decisão.




Figura 1-Algoritmo Árvore de Decisão.

Neste caso, estamos perante um problema de classificação discreto que será a previsão do diagnóstico do paciente, se tem ou não doença, consoante a análise dos dados fornecidos.

Existem também técnicas baseadas na técnica de árvores de decisão, como por exemplo, o método Random Forest e Gradient Boosting.

Random Forest

As Random Forest [3] utilizam várias árvores de decisão individuais que funcionam em conjunto. Cada árvore faz a previsão do atributo target individualmente, e, posteriormente, é escolhida a previsão mais frequente entre as árvores, como mostrado na figura 2. Assim, quantas mais árvores o algoritmo usar, mais precisão se verificará.




Figura 2-Algoritmo Random Forest [3].

Por outro lado, este algoritmo, previne a existência de overfitting na previsão de resultados. O overfitting é um fenómeno que ocorre quando o modelo se ajusta muito bem ao conjunto de dados de treino observado, mas não funciona, ou mostra-se ineficaz para outros dados fornecidos.

A técnica Random Forest pode apresentar resultados muito bons já que os erros cometidos por cada árvore são compensados pelas outras árvores. Por outras palavras, as árvores funcionam sem correlação entre si, pelo que os erros cometidos por uma das árvores não afetam as outras e podem afetar pouco o resultado final, já que este é determinado pelo conjunto das mesmas. No geral, é um algoritmo eficiente para todos os tipos de dataset incluindo grandes dataset ou com vários missing values.

Gradient Boosting

O algoritmo Gradient Boosting [4] é uma técnica utilizada em Machine Learning para problemas de regressão e classificação. Esta técnica produz um modelo de previsão na forma de um conjunto de modelos de previsão fracos, geralmente árvores de decisão.

O objetivo deste algoritmo é criar uma corrente de modelos fracos, onde cada um tem como objetivo minimizar o erro do modelo anterior, com recurso a uma função de perda.

Aos ajustes de cada modelo fraco, é multiplicado um valor denominado de taxa de aprendizagem, que serve para determinar o impacto de cada árvore no modelo final. Quanto menor for esse valor, menor será a contribuição de cada árvore [4].

A figura seguinte representa o esquema da técnica *Gradient Boosting*.




Figura 3-Arquitetura do algoritmo Gradient Boosting [4].

Redes Neurais Artificiais

Uma Rede Neuronal Artificial (RNA) [5] é uma estrutura de unidades computacionais interligadas designadas de neurónios, com capacidade de aprendizagem, tendo por base um modelo simplificado do sistema nervoso central. Estas apresentam várias vantagens, sendo a principal, a grande aproximação à construção de verdadeiros sistemas inteligentes, devido ao facto de apresentar uma grande capacidade de responder adequadamente a novos problemas com base nos problemas passados .

As RNA tem como unidade de processamento chave o nodo. O nodo comporta-se como um comparador que produz uma saída quando o efeito cumulativo das entradas excede um dado valor limite. Este é identificado pela sua posição na rede e caracterizado pelo seu valor de estado.

Para a informação do nodo poder circular para outros nodos, estes têm de estar interconectados entre si por os axónios. Sabe-se ainda que o ponto de interconexão entre os axónios e nodos se denominam de sinapses.

O valor da sinapse que irá entrar no neurónio determinará a importância do sinal, podendo ter um peso excitativo, inibitório ou nulo. O valor de ativação varia com o tempo e com o modelo adotado, sendo que o valor de transferência é calculado como uma função do valor de ativação, determinando o valor que será colocado na saída e assim transferido através do axónio. Esta variação no tempo determina a aprendizagem da RNA.




Figura 4-Rede Neuronal Artificial.

Deste modo, o treino de uma RNA dá-se por aplicação de regras de aprendizagem, de maneira a variar os pesos das ligações/sinapses. Para uma melhor afinação destes pesos tem-se em consideração os métodos de treino, quantidade de nodos, ligações dos neurónios e a sua topologia.

2.1.2 Aprendizagem não supervisionada

Neste tipo de aprendizagem, não são conhecidos os resultados sobre os casos ou seja não está associado nenhum atributo/classe/target, tendo-se apenas conhecimento do enunciado do problema. Assim, o modelo tem de ser capaz encontrar padrões nos dados fornecidos, modelando a estrutura ou a distribuição destes. Este tipo de aprendizagem é muito útil nos problemas onde o conhecimento dos dados é bastante reduzido.

A aprendizagem não supervisionada subdivide-se em duas categorias: aglomeração/segmentação/clustering e associação. Os problemas de segmentação ocorrem quando se pretende organizar os dados em grupos coerentes, com base em relações entre os atributos presentes. A aprendizagem por associação pretende conhecer regras que associem o comportamento demonstrado pelos dados.

2.1.3 Aprendizagem por reforço

Este paradigma, apesar de não conter informação sobre os resultados pretendidos, permite efetuar uma avaliação do problema através de um sistema tentativa erro, avaliando ainda se os resultados produzidos são bons ou maus. Este sistema utiliza técnicas de auto-alimentação, por influência da noção de recompensa/penalização por cada uma das ações efetuadas, sendo o seu objetivo a maximização da recompensa total.

Como se mostrará mais à frente, neste trabalho utilizou-se uma abordagem por aprendizagem supervisionada.

2.2 Análise estatística e exploração de dados

A utilização da estatística permite efetuar o processo de recolha, organização, análise e exploração de dados [6], correspondendo a um dos primeiros passos na criação de sistemas de ML. Esta análise e exploração é muito importante para o conhecimento do tipo de dados e consequentemente para sustentar decisões válidas posteriores. Neste sentido, é importante analisar a quantidade e qualidade dos dados, devendo ser efetuadas as análises em várias vertentes, como através de histogramas, distribuições e correlações, métricas estatísticas como o desvio padrão, assim como a mediana, moda e média que apesar de serem cálculos simples são vastamente utilizados e de bastante utilidade na análise inicial de dados.

Como já é sabido, a média calcula-se através da soma de todos os valores do conjunto de dados a dividir pelo número de elementos do conjunto. Como esta é alterada consoante os valores da amostra, é mais indicada para casos em que os dados são distribuídos de forma uniforme, sem grandes discrepâncias. A moda representa o valor mais frequente de um conjunto de dados e a mediana corresponde ao valor central de uma lista de dados organizados de forma crescente ou decrescente sendo considerada uma medida de centralidade.

Por outro lado, o desvio padrão tem como objetivo medir o grau de variabilidade de um conjunto de dados, ou seja, indica o quanto um conjunto de dados é uniforme, sendo que quanto mais próximo de zero, mais homogêneos serão [7].

Por sua vez, o histograma é um tipo de gráfico que facilita a observação dos valores e utilizado como indicador de dispersão de dados [8]. O gráfico apresenta barras com diferentes alturas dependendo da frequência dos valores do intervalo.

Outro aspeto importante na análise destes gráficos é a avaliação do ajuste de uma distribuição através da linha de distribuição ajustada. Esta permite avaliar se a altura das barras segue a configuração da linha. Considera-se um mau ajuste se a altura estiver distante da linha de ajuste. É muito comum procurar identificar-se a distribuição de gauss nos dados. Esta distribuição de gauss a distribuição normal é a mais utilizada na estatística e consiste numa curva simétrica á volta do seu ponto médio sendo que a área sob essa curva representa a probabilidade de ocorrer o evento. Esta está presente em vários fenómenos naturais e pode significar a presença de uma boa amostra.




Figura 5- Histograma e distribuição Normal [9].

Por outro lado, dados assimétricos e *outliers* indicam que estes dados podem ser anormais. Quando os dados são assimétricos, indica que não há uma distribuição normal dos dados e esta assimetria pode-se encontrar no lado superior ou inferior do gráfico. Os dados são considerados *outliers* quando são valores distantes dos outros valores dos dados e podem interferir bastante nos resultados finais. Estes costumam ser identificados através de uma boxplot e é aconselhada a remoção destes valores de modo a obter resultados mais precisos.

Uma boxplot ou gráfico de bigode é composto por uma caixa que vai do quartil inferior Q1 ao quartil superior Q3. A mediana encontra-se representada com um traço horizontal no meio deste. Sabe-se ainda que a distância que vai desde o quartil 1 ao quartil 3 é denominada de distância interquartil. Acima e abaixo destas, são representados os valores ditos normais. Os valores que excedam estes intervalos, ou seja excedem $1,5 \times \text{IQR}$, são denominados *outliers* e estão representados com círculos.




Figura 6-Exemplo de Box Plot e Outliers [9].

É também importante ter em atenção a correlação entre atributos. Esta mede o quanto, em média, dois ou mais atributos dependentes, variam entre si. Quando esta é igual a 1, um dos atributos pode ser eliminado pois não fornece informações novas para o problema. Quando é perto de 1 mostra que os atributos têm uma relação forte entre si [9]. Por outro lado, quando está perto de -1 mostra que os atributos têm uma correlação inversa, ou seja, os atributos não tem relação entre si.

2.3 Machine Learning Pipeline

A criação de um modelo de machine learning pode ser dividida em diversas etapas. Um pipeline de machine learning corresponde a um conjunto de fases de um fluxo processual desde os dados iniciais até à criação e usos dos modelos, como é ilustrado na figura 7.




Figura 7-Machine Learning Pipeline [10].

Tipicamente, o algoritmo de machine learning tenta encontrar padrões nos dados e usa-os para a criação de um modelo. Para tal, é aconselhável seguir as seguintes etapas [11]:

1. **Definição do problema:** é necessário a definição do problema inicial;
2. **Recolha/Carregamento de dados:** é necessário a identificação e recolha dos dados a serem utilizados;
3. **Preparação de dados:** devido a impurezas nos dados do “mundo real”, estes devem ser processados. Geralmente, esta fase envolve lidar com valores em falta, remoção de registos duplicados, normalização e correção de outras possíveis erros;
4. **Divisão de dados:** divisão de dados em subconjuntos de treino, testes e avaliação;
5. **Avaliação do modelo:** avaliação do modelo usando os subconjuntos de treino, teste e avaliação de modo a *accuracy* (exatidão) do modelo. Este é um processo iterativo onde

vários algoritmos devem ser testados até que exista um modelo suficientemente bom (elevada *accuracy*).

6. **Implementação do modelo:** após o modelo ser criado, é exposto através de uma Interface de Programação de Aplicação e incorporado em frameworks de tomada de decisão como parte de uma solução de análise;
7. **Avaliação de desempenho:** o modelo deve ser monitorizado continuamente para ver como ele comportou com novos dados, e se é necessário calibrar de novo.

2.4 Métricas de avaliação do modelo

As métricas de avaliação [12] são parâmetros normalmente usados na avaliação do desempenho de modelos de aprendizagem automática. A seguir, vão ser explicitados alguns conceitos importantes.

A Matriz de confusão é dos primeiros parâmetros a ser analisados. Esta matriz corresponde ao resultado de valores previstos em problemas de classificação. Através da matriz de confusão consegue medir-se o sucesso no que diz respeito às previsões do modelo comparando-as com as atuais. Deste modo, é possível retirar da matriz de confusão o número de falsos positivos (FP), falsos negativos (FN), verdadeiros positivos (TP) e verdadeiros negativos (TN). Através destes valores consegue-se calcular a *Accuracy*.

A *Accuracy* corresponde á quantidade de previsões corretas dividido pela quantidade total de observações:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

		True Class	
		Positive	Negative
Predicted Class	Positive	TP	FP
	Negative	FN	TN

Figura 8-Matriz de Confusão [9].

Outro parâmetro de avaliação é o *Cohen's Kappa* ou coeficiente de Cohen, que representa uma medida quantitativa de confiabilidade para dois avaliadores que avaliam o mesmo parâmetro [9]. Os valores menores ou iguais a 0 não apresentam concordância, entre 0,01 e 0,20 quase nenhuma, entre 0,21 e 0,40 uma concordância razoável, de 0,41 a 0,60 moderada, entre 0,61 e 0,80 uma substancial concordância e entre 0,81 e 1,00 uma concordância quase perfeita.

Por outro lado, outra métrica utilizada é a curva ROC que corresponde à curva *Receiver Operating Characteristics* que encontra o desempenho de um modelo de classificação em diferentes limites de classificação por meio da relação entre a taxa de verdadeiros positivos (eixo dos Y) e a taxa de falsos positivos (eixo dos X), variando o threshold (ponto de corte na probabilidade estimada).




Figura 9- Curva ROC.

Dessa forma, a *Curva ROC* permite encontrar o *threshold* em que existe otimização da taxa de verdadeiros positivos em função da taxa de falsos positivos (Curva 1 da fig.9). O ponto onde ocorre esta otimização é aquele que se encontra mais próximo do canto superior esquerdo do gráfico da *curva ROC* [9]. Sendo assim, o objetivo de analisar a predição de um modelo é garantir que ele irá detetar o máximo possível de verdadeiros positivos, enquanto minimiza os falsos positivos.

Um outro parâmetro geralmente utilizado na avaliação de modelos é a *F-Measure*. Esta é uma métrica de avaliação que combina pontuações de precisão e recuperação. A precisão mede quantas das previsões “positivas” feitas pelo modelo estavam corretas. A *recall* mede quantas das amostras de classes positivas presentes no conjunto de dados foram identificadas corretamente pelo modelo. *F-Measure* é uma métrica melhor que a *Accuracy*, principalmente em casos onde falsos positivos e falsos negativos possuem impactos diferentes para o modelo. Um valor de *F-Measure* é considerado perfeito quando é 1 e que o modelo falha quando é 0. Logo, apesar de depender do *dataset*, regra geral pode classificar-se um resultado de *F-Measure* como muito bom se maior que 0,9, bom no intervalo de 0,8 a 0,9, e razoável entre 0,5 e 0,8, menor que 0,5 é um valor considerado muito mau. Quanto mais próximo de 1 mais baixo será o número de falsos positivos e falsos negativos [13].

Duas outras métricas que pode ser utilizada é a sensibilidade e especificidade. Esta métrica avalia a capacidade do método de detetar com sucesso resultados classificados como positivos. Por outro lado, a especificidade avalia a capacidade do método de detetar resultados negativos.

2.5 Plataforma KNIME

O KNIME¹ é uma plataforma que através da utilização de uma interface gráfica permite a análise de dados. O utilizador, através da utilização desta, vai criando um fluxo de trabalho de nodos, mais propriamente um pipeline. No KNIME, os dados são criados ao arrastar e soltar na página de trabalho. Cada nó, por sua vez, implementa uma determinada tarefa, sendo que posteriormente se vai fazendo a conexão entre estes de forma que os dados vão passando e sendo tratados em cada nodo. Neste trabalho vai ser utilizada esta plataforma.

3. Desenvolvimento do Sistema de Aprendizagem Automática

Após uma análise do enunciado do trabalho e de uma breve observação dos dados fornecidos percebeu-se que o objetivo do trabalho seria o desenvolvimento de um modelo de aprendizagem automática de modo a diagnosticar a existência ou não de doença cardíaca, isto é um sistema capaz de resolver problemas de classificação e previsão.

Para isso foram fornecidos quatro *datasets* em formato *csv*, em quatro ficheiros diferentes correspondentes a quatro cidades diferentes: Cleveland com 303 registos, LongBeach com 200 registos, Hungarian com 294 registos e Switzerland com 123 registos, cujos atributos correspondem aos seguintes parâmetros fisiológicos:

- **Age:** Idade do paciente;
- **Sex:** Sexo do paciente;
- **Cp:** Dor no peito (1-4);
- **Trestbps:** Pressão sanguínea em repouso;
- **Chol:** Colesterol;
- **Fbs:** Açúcar no sangue em jejum. (0-1);
- **Restecg:** Resultados de uma eletrocardiograma em repouso (0,1,2);
- **Thalach:** Frequência cardíaca máxima alcançada;
- **Exang:** Angina (dores peitorais) induzidas pelo exercício (0,1);
- **Oldpeak:** Depressão no segmento ST induzida pelo exercício em relação ao repouso;
- **Slope:** Inclinação do pico de exercício segmento ST (1,2,3);
- **Ca:** Número de grandes vasos (0,1,2) colorido por fluoroscopia;
- **Thal:** 3 = normal; 6 = defeito fixo; 7 = defeito reversível;

- **Num:** Atributo previsto, se tem ou não problemas cardíacos numa escala que pode variar de 0 a 4.

Os *datasets* iniciais fornecem o atributo target/classe que indica se o paciente tem ou não doença cardíaca. Como é fornecido este atributo o modelo vai ser desenvolvido segundo a abordagem de aprendizagem supervisionada usando vários algoritmos de IA como as árvores de decisão e também das redes neuronais. No software utilizado, KNIME, são disponibilizados estas técnicas e também subvariantes da primeira como a técnica Random Forest e ainda Gradient Boosted. Assim, foram desenvolvidos quatro modelos correspondentes a estas técnicas mencionadas para a criação de modelos de classificação/previsão.

Como foi explicitado anteriormente na parte preliminares para desenvolver este tipo de modelo é necessário percorrer certas etapas que vão ser explicitadas a seguir com detalhe.

3.1 Pipeline

Com base no processo descrito na seção dos preliminares sobre o Machine Learning Pipeline, para o desenvolvimento deste trabalho foram desenvolvidos vários pipelines. Na parte Anexo, ilustra-se um dos exemplos e, exemplos estes que serão descritos com mais detalhe nas seções seguintes.

3.2. Carregamento de dados

Primeiramente, foram importados os quatro *datasets* para o workflow da plataforma KNIME. Posteriormente, foi utilizado o nodo CSV READER para carregar cada ficheiro de dados para o ambiente de trabalho da plataforma.



Figura 10-Nodo CSV Reader.

Através da figura 11, é possível visualizar uma pequena amostra de um *dataset* que irá ser analisado.

Row ID	I age	I sex	I cp	I trestbps	I chol	I fbs	I restecg	I thalach	I exang	D oldpeak	I slope	I ca	I thal	I num
Row0	63	1	1	145	233	1	2	150	0	2.3	3	0	6	0
Row1	67	1	4	160	286	0	2	108	1	1.5	2	3	3	2
Row2	67	1	4	120	229	0	2	129	1	2.6	2	2	7	1
Row3	37	1	3	130	250	0	0	187	0	3.5	3	0	3	0
Row4	41	0	2	130	204	0	2	172	0	1.4	1	0	3	0
Row5	56	1	2	120	236	0	0	178	0	0.8	1	0	3	0
Row6	62	0	4	140	268	0	2	160	0	3.6	3	2	3	3
Row7	57	0	4	120	354	0	0	163	1	0.6	1	0	3	0

Figura 11-dataset- Cleveland.

Verifica-se que o *dataset* contém os 14 atributos que vão ser usados para efeitos de análise e estudo sendo que cada um contribui com informação relevante associada e relacionada ao valor do *target* num.

Este atributo, encontra-se na última coluna (denominada por “num”) e determina a ausência ou não de problemas cardíacos medidos numa escala de 0 a 4. É importante salientar que esta escala varia em cada *dataset*, por exemplo, no *dataset* Hungarian só existem valores 0 ou 1. O valor 0 representa ausência de doenças cardíacas, enquanto 1,2,3,4 representam existência de doenças cardíacas. É importante ressaltar que todos os dados são do tipo inteiro (I), à exceção da coluna de dados Oldpeak que é do tipo *Double* (D).

3.3 Exploração e Análise de dados

Os diferentes ficheiros dos *datasets* em formato csv foram individualmente analisados de forma a perceber se os dados se encontravam com a mesma formatação e forma. Por outro lado, também é importante perceber se os diferentes *datasets* podem ser tratados da mesma forma ou se requerem tratamentos diferentes adequados ao tipo de dados encontrado.

Assim, através da plataforma KNIME, foram utilizados vários nodos nomeadamente da área da estatística para ter uma melhor noção do tipo de dados.

Posteriormente, foram aplicados a todos os ficheiros csv seguintes nodos:




Figura 12-Nodos Data Explorer, Statistics, Linear Correlation e Box Plot utilizados para a Exploração de dados.

Estes nodos vão permitir uma visualização interativa dos dados. Na plataforma, o nodo *Csv Reader* utilizado na etapa anterior estará ligado aos quatro nodos mostrados acima, como se pode observar na figura 13:




Figura 13-Fluxo utilizado para a Exploração de Dados.

A seguir descrevem-se as informações retiradas dos nodos utilizados acima para cada *dataset*.

3.3.1 Dataset Cleveland

Do nodo *Data Explorer* consegue-se obter uma tabela com as informações mais importantes de todas as colunas, como por exemplo, o mínimo, máximo, média e desvio padrão, como se pode observar abaixo.

Column	Column	Minimum	Maximum	Mean	Deviation	Variance	Skewness
age		29	77	54.439	9.039	81.697	-0.209
sex		0	1	0.680	0.467	0.218	-0.775
cp		1	4	3.158	0.960	0.922	-0.842
trestbps		94	200	131.690	17.600	309.751	0.706
chol		126	564	246.693	51.777	2680.849	1.136
fbs		0	1	0.149	0.356	0.127	1.987
restecg		0	2	0.990	0.995	0.990	0.020
thalach		71	202	149.607	22.875	523.266	-0.537
exang		0	1	0.327	0.470	0.221	0.743
oldpeak		0	6.200	1.040	1.161	1.348	1.270
slope		1	3	1.601	0.616	0.380	0.508
ca		0	3	0.672	0.937	0.879	1.189
thal		3	7	4.734	1.940	3.762	0.244
num		0	4	0.937	1.229	1.509	1.058

Figura 14-Informação Retirada do nodo Data Explorer no Dataset Cleveland.

Por outro lado, retiram-se outras informações importantes como a existência de desvios padrão muito altos, no atributo *chol*, por exemplo, que podem significar dados muito díspares que podem necessitar de normalização ou ainda a existência de *outliers*.

No atributo *target*, verifica-se que este atributo tem mínimo 0 e máximo 4, isto significa que o diagnóstico da doença é 0 para não ter doença ou 1, 2, 3, 4 para ter doença. Mais a frente verifica-se que não é o caso para todos os *datasets* pelo que estes valores vão ter de ser alterados.

Para verificar a distribuição dos dados pode-se usar o nodo *Statistics* que apresenta parte das informações dadas pelo *Data Explorer* mas apresenta também o histograma desses dados. Na figura seguinte ilustra-se a informação relevante retirada:




Figura 15-Informação retirada do nodo *Statistics* no *Dataset Cleveland*.

Com o objetivo de se analisar os missing values e as distribuições dos dados deste dataset, nas figuras anteriores verifica-se que não existe uma quantidade elevada de missing values pelo que, o tratamento destes será mais fácil. Por sua vez, na análise da distribuição através dos histogramas, observa-se que o atributo *age* tem valores contínuos (no intervalo 29 e 77 anos) e os restantes atributos são discretos.

Seguidamente, para verificar se existem *outliers* nos valores contínuos, utilizou-se o *Box plot*, obtendo-se o seguinte gráfico:




Figura 16-Boxplot do Dataset Cleveland.

Verifica-se que os atributos *trestbps* e *chol* apresentam alguns outliers que vão ter de ser posteriormente tratados. Por fim, foram também calculadas as correlações lineares entre todos atributos.

Na figura 17 verifica-se através da matriz de cores (vulgarmente designada por *heatmap*) a respetiva correlação entre os mesmos, sendo a cor vermelha representativa da correlação com valor -1 e a cor azul representativa da correlação com valor de 1. As cores mostradas pertencem a um espectro entre as cores extremas relativas à correlação igual a 1 e a -1. Esta forma de mapa de cores mostra de forma mais interativa os valores de correlação passando o cursor na célula que se pretende.




Figura 17-Matriz de Cores sobre a Correlação do Dataset Cleveland.

No entanto, também se pode retirar a matriz de correlação com todos os valores visíveis:

Row ID	D age	D sex	D cp	D trestbps	D chol	D fbs	D restecg	D thalach	D exang	D oldpeak	D slope	D ca	D thal	D num
age	1.0	-0.09754...	0.10413...	0.284945919...	0.208950...	0.11853...	0.14886759...	-0.3938058...	0.0916607...	0.2038054...	0.1617695...	0.362604...	0.127388...	0.22285341...
sex	-0.0975422...	1.0	0.01008...	-0.06445589...	-0.199914...	0.04786...	0.02164735...	-0.0486632...	0.1462014...	0.1021726...	0.0375328...	0.093184...	0.380935...	0.22446851...
cp	0.10413895...	0.01008...	1.0	-0.03607724...	0.072318...	-0.0399...	0.06750523...	-0.3344217...	0.3840595...	0.2022765...	0.1520504...	0.233214...	0.265245...	0.40707542...
trestbps	0.28494591...	-0.06445...	-0.0360...	1.0	0.130120...	0.17534...	0.14656038...	-0.0453508...	0.0647624...	0.1891709...	0.1173815...	0.098773...	0.133553...	0.15775407...
chol	0.20895026...	-0.19991...	0.07231...	0.130120108...	1.0	0.00984...	0.17104253...	-0.0034318...	0.0613103...	0.0465639...	-0.0040618...	0.119000...	0.014214...	0.07090875...
fbs	0.11853024...	0.04786...	-0.0399...	0.175340226...	0.009841...	1.0	0.06956449...	-0.0078541...	0.0256651...	0.0057472...	0.0598941...	0.145477...	0.071358...	0.05918609...
restecg	0.14886759...	0.02164...	0.06750...	0.146560387...	0.171042...	0.06956...	1.0	-0.0833894...	0.0848669...	0.1141328...	0.1339456...	0.128342...	0.024531...	0.18369634...
thalach	-0.3938058...	-0.04866...	-0.3344...	-0.04535087...	-0.003431...	-0.0078...	-0.08338943...	1.0	-0.378103...	-0.343085...	-0.3856011...	-0.26424...	-0.27963...	-0.4150404...
exang	0.09166077...	0.14620...	0.38405...	0.064762455...	0.061310...	0.02566...	0.08486695...	-0.3781034...	1.0	0.2882228...	0.2577483...	0.145569...	0.329679...	0.39705730...
oldpeak	0.20380548...	0.10217...	0.20227...	0.189170970...	0.046563...	0.00574...	0.11413281...	-0.3430853...	0.2882228...	1.0	0.5775368...	0.295832...	0.341003...	0.50409197...
slope	0.16176955...	0.03753...	0.15205...	0.117381584...	-0.004061...	0.05989...	0.13394568...	-0.3856011...	0.2577483...	0.5775368...	1.0	0.110119...	0.287231...	0.37795660...
ca	0.36260452...	0.09318...	0.23321...	0.098773257...	0.119000...	0.14547...	0.12834265...	-0.2642462...	0.1455696...	0.2958321...	0.1101191...	1.0	0.256382...	0.51890924...
thal	0.12738862...	0.38093...	0.26524...	0.133553897...	0.014214...	0.07135...	0.02453108...	-0.2796306...	0.3296799...	0.3410039...	0.2872319...	0.256382...	1.0	0.50992290...
num	0.22285341...	0.22446...	0.40707...	0.157754076...	0.070908...	0.05918...	0.18369634...	-0.4150404...	0.3970573...	0.5040919...	0.3779566...	0.518909...	0.509922...	1.0

Figura 18-Matriz de Correlação do Dataset Cleveland.

Neste caso, verifica-se que não existem atributos com correlações muito negativas, isto é, muito perto de -1. Isto significa que não é necessário eliminar colunas por poder ainda existir alguma correlação entre elas.

3.3.2 Dataset LongBeach

Para a exploração de dados deste *dataset* também foram usados os nodos mostrados acima. Obtendo-se estes dados gerais deste *dataset* a partir do nodo *Data Explorer*:

Column	Exclude Column	Minimum	Maximum	Mean	Standard Deviation	Variance	Skewness	Kurtosis
age	☐	35	77	59.350	7.812	61.023	-0.404	0.631
sex	☐	0	1	0.970	0.171	0.029	-5.552	29.117
cp	☐	1	4	3.505	0.796	0.633	-1.649	2.093
trestbps	☐	0	190	133.764	21.538	463.874	-1.286	9.473
chol	☐	0	458	178.746	114.035	13004.034	-0.562	-0.823
fbss	☐	0	1	0.352	0.479	0.229	0.623	-1.629
restecg	☐	0	2	0.735	0.683	0.467	0.391	-0.840
thalach	☐	69	180	122.796	21.990	483.575	0.128	-0.189
exang	☐	0	1	0.646	0.480	0.230	-0.618	-1.640
oldpeak	☐	0	4	1.230	1.221	1.492	0.531	-0.859
slope	☐	1	3	2.133	0.668	0.446	-0.157	-0.739
ca	☐	0	0	0	0	0	?	?
thal	☐	3	7	6.294	1.292	1.668	-2.024	2.929
num	☐	0	4	1.520	1.219	1.487	0.297	-1.036

Figura 19-Informação retirada do nodo *Data Explorer* no Dataset *LongBeach*.

A informação direta que se pode retirar mostra que o atributo *ca* tem mínimo e máximo 0, o que significa que provavelmente esta coluna tem todos os seus valores a 0 tal que no processamento de dados será necessário ter esta situação em conta.

Por outro lado, o atributo *chol* tem um desvio muito grande e um mínimo de 0, o que pode significar um erro na introdução dos dados ou a existência de um outlier nesse valor, que podem ser verificados ou não no box plot usado a frente. Pode observar-se também que neste *dataset* o atributo target *num* varia de 0 a 4, e também será necessário tratar estes dados de modo a ficarem coerentes com os outros *datasets*.

Do nodo *statistics*, retirou-se esta informação:




Figura 20- Informação retirada do nodo *Statistics* no Dataset *LongBeach*.

Conforme se ilustra nas figuras anteriores verifica-se também a existência de muitos missing values nos atributos *oldpeak*, *slope*, *ca* e *thal*. Nestas colunas cerca de metade ou mais dos registos totais tem os seus valores como missing values.

Neste caso, é importante decidir o que fazer acerca destes valores pois eliminá-los pode levar à perda de informação, no entanto, dar-lhes um valor como a média ou mediana pode adulterar os valores reais. Verifica-se também que a distribuição das idades, varia entre 35 e 77 anos

Através do nodo *boxplot* verificou-se que na verdade não existem muitos *outliers* nos dados fornecidos. Pode observar-se alguns no atributo idade, no entanto não são *outliers* extremos.




Figura 22-Boxplot do Dataset LongBeach.

Por fim, pelo nodo *Linear Correlation* observa-se mais uma vez que não existem atributos com uma forte relação ao ponto de poderem ser eliminadas, como se pode observar na matriz de correlação ou na matriz de cores representadas abaixo.

Row ID	D age	D sex	D cp	D trestbps	D chol	D fbs	D restecg	D thalach	D exang	D oldpeak	D slope	D ca	D thal	D num
age	1.0	0.034...	-0.0382...	0.21097987...	0.069137...	0.12781...	0.002400113...	-0.1741247...	0.1568227...	0.183086031...	0.148602...	?	0.17642...	0.287288...
sex	0.03423...	1.0	0.0380...	0.01381964...	-0.09620...	-0.0553...	0.060620741...	-0.0017474...	0.0181545...	0.106811484...	0.124613...	?	-0.1386...	0.147469...
cp	-0.0382...	0.038...	1.0	0.09724599...	0.066278...	-0.0477...	0.034789801...	-0.1603063...	0.2359348...	0.055932558...	0.047762...	?	0.21333...	0.168210...
trestbps	0.21097...	0.013...	0.0972...	1.0	0.176921...	0.22602...	0.106917597...	-0.0131773...	0.2225499...	0.118021962...	0.109788...	?	0.23013...	0.172576...
chol	0.06913...	-0.096...	0.0662...	0.17692168...	1.0	0.16085...	0.025153886...	-0.0482686...	0.1020159...	0.001549373...	0.080450...	?	-0.1713...	0.077999...
fbs	0.12781...	-0.055...	-0.0477...	0.22602424...	0.160850...	1.0	0.167657080...	0.06168239...	-0.2592992...	-0.12212231...	0.023457...	?	0.05992...	0.051011...
restecg	0.00240...	0.060...	0.0347...	0.10691759...	0.025153...	0.16765...	1.0	0.01427359...	-0.0931411...	-0.12388960...	-0.02781...	?	0.11087...	-0.03280...
thalach	-0.1741...	-0.001...	-0.1603...	-0.01317733...	-0.04826...	0.06168...	0.014273591...	1.0	-0.0750569...	0.179166824...	-0.16412...	?	-0.4145...	-0.09439...
exang	0.15682...	0.018...	0.2359...	0.22254998...	0.102015...	-0.2592...	-0.09314115...	-0.0750569...	1.0	0.314143152...	0.149392...	?	0.25835...	0.304295...
oldpeak	0.18308...	0.106...	0.0559...	0.11802196...	0.001549...	-0.1221...	-0.12388960...	0.17916682...	0.3141431...	1.0	0.331318...	?	0.20941...	0.457514...
slope	0.14860...	0.124...	0.0477...	0.10978807...	0.080450...	0.02345...	-0.02781722...	-0.1641238...	0.1493923...	0.331318777...	1.0	?	-0.0277...	0.175686...
ca	?	?	?	?	?	?	?	?	?	?	?	1.0	?	?
thal	0.17642...	-0.138...	0.2133...	0.23013046...	-0.17131...	0.05992...	0.110870766...	-0.4145986...	0.2583525...	0.209410270...	-0.02775...	?	1.0	0.084002...
num	0.28728...	0.147...	0.1682...	0.17257698...	0.077999...	0.05101...	-0.03280011...	-0.0943917...	0.3042959...	0.457514246...	0.175686...	?	0.08400...	1.0

Figura 23-Matriz de Correlação do Dataset LongBeach.

No entanto, também não existem variáveis com correlação inversa suficiente que possam ser eliminadas por não mostrarem qualquer relação com o atributo target. Existem células para as quais não foi possível calcular a sua correlação pois o atributo ca não está bem definido, isto é, todos os seus valores são 0.




Figura 24- Matriz de Correlação a cores do Dataset LongBeach.

3.3.3 Dataset Hungarian

Quando aplicado o nodo *Data Explorer* como nos outros datasets o resultado obtido é:

Column	Exclude Column	Minimum	Maximum	Mean	Standard Deviation	Variance	Skewness	Kurtosis
age	☐	28	66	47.827	7.812	61.024	-0.284	-0.503
sex	☐	0	1	0.724	0.448	0.200	-1.010	-0.986
cp	☐	1	4	2.983	0.965	0.931	-0.218	-1.422
trestbps	☐	92	200	132.584	17.627	310.696	0.738	0.810
chol	☐	85	603	250.849	67.658	4577.566	1.433	4.578
fbt	☐	0	1	0.070	0.255	0.065	3.391	9.562
restecg	☐	0	2	0.218	0.461	0.212	1.983	3.198
thalach	☐	82	190	139.130	23.590	556.476	-0.087	-0.590
exang	☐	0	1	0.304	0.461	0.212	0.858	-1.273
oldpeak	☐	0	5	0.586	0.909	0.826	1.549	2.181
slope	☐	1	3	1.894	0.339	0.115	-1.810	4.064
ca	☐	0	0	0	0	0	0	?
thal	☐	3	7	5.643	1.615	2.608	-0.959	-0.788
num	☐	0	1	0.361	0.481	0.231	0.584	-1.671

Figura 26-Informação retirada do nodo Data Explorer no Dataset Hungarian.

No geral, observa-se que existem desvios padrão elevados o que pode querer dizer que os dados podem ter de ser normalizados ou que existem alguns *outliers*. No entanto, a informação mais relevante retirada é que o atributo *ca*, como no *dataset* anterior não está definido, assim, vai ter de ser retirado nas etapas seguintes do processo.

Do nodo *Statistics* podemos retirar mais uma vez os dados gerais aliados aos histogramas de cada atributo.






Figura 27-Informação retirada do nodo Statistics do Dataset Hungarian.

Podemos verificar que para os atributos *slope*, *ca*, *thal* existem muitos *missing values*. De facto, no total de 294 registos, nestes atributos, maior parte são *missing values*. Assim, estas colunas vão ter de ser tratadas na etapa seguinte do processo pipeline.

Neste *dataset* pode-se verificar através desta tabela, que o atributo *target num* varia entre 0 e 1. Assim, os *datasets* restantes terão de ser tratados de forma a ficarem neste intervalo de diagnóstico. Por outro lado, consegue verificar-se também que a distribuição das idades varia entre 28 e 66 anos.

Para verificar a existência de outliers utilizou-se novamente o nodo *Boxplot*, obtendo se o seguinte resultado:




Figura 28- Boxplot obtido e outliers do Dataset Hungarian.

Existem no atributo colesterol valores considerados outliers pelo que será necessário tratá-los mais a frente no fluxo processual.

Mais uma vez, também foram calculadas as correlações lineares para todos os atributos entre si, obtendo-se a seguinte matriz de correlação:

Row ID	D age	D sex	D cp	D trestbps	D chol	D fbs	D restecg	D thalach	D exang	D oldpeak	D slope	D ca	D thal	D num
age	1.0	0.01361...	0.14582...	0.2452032...	0.09097...	0.18221...	0.05198948...	-0.4594201...	0.23892507...	0.17770666...	-0.0679996...	?	0.274092...	0.15931...
sex	0.01361752...	1.0	0.24987...	0.0891118...	0.02879...	0.04279...	-0.10461408...	-0.1117811...	0.15492504...	0.11893078...	0.2139211...	?	-0.13001...	0.27278...
cp	0.14582616...	0.24987...	1.0	0.0856309...	0.13884...	0.03334...	-0.01815391...	-0.3704395...	0.49467444...	0.35310924...	0.3928411...	?	-0.04862...	0.50586...
trestbps	0.24520328...	0.08911...	0.08563...	1.0	0.08426...	0.09541...	0.01391432...	-0.1849614...	0.21385637...	0.20684800...	0.0355358...	?	0.206153...	0.13971...
chol	0.09097893...	0.02879...	0.13884...	0.0842644...	1.0	0.12290...	0.05024909...	-0.1276762...	0.16851837...	0.10934272...	0.1178382...	?	-0.11340...	0.20931...
fbs	0.18221174...	0.04279...	0.03334...	0.0954159...	0.12290...	1.0	0.04916043...	-0.0714891...	0.11616968...	0.06231605...	0.2013152...	?	0.164352...	0.16323...
restecg	0.05198948...	-0.1046...	-0.0181...	0.0139143...	0.05024...	0.04916...	1.0	0.00448095...	0.04539173...	0.04219308...	-0.0312220...	?	-0.18899...	-0.02993...
thalach	-0.4594201...	-0.1117...	-0.3704...	-0.184961...	-0.1276...	-0.0714...	0.00448095...	1.0	-0.4019795...	-0.30302752...	-0.1753560...	?	-0.45613...	-0.33139...
exang	0.23892507...	0.15492...	0.49467...	0.2138563...	0.16851...	0.11616...	0.04539173...	-0.4019795...	1.0	0.63210830...	0.4188952...	?	0.181141...	0.58384...
oldpeak	0.17770666...	0.11893...	0.35310...	0.2068480...	0.10934...	0.06231...	0.04219308...	-0.3030275...	0.63210830...	1.0	0.1218172...	?	0.116806...	0.54570...
slope	-0.0679996...	0.21392...	0.39284...	0.0355358...	0.11783...	0.20131...	-0.03122206...	-0.1753560...	0.41889528...	0.12181722...	1.0	?	-0.08894...	0.54342...
ca	?	?	?	?	?	?	?	?	?	?	?	1.0	?	?
thal	0.27409243...	-0.1300...	-0.0486...	0.2061533...	-0.1134...	0.16435...	-0.18899056...	-0.4561334...	0.18114169...	0.11680645...	-0.0889460...	?	1.0	0.52571...
num	0.15931455...	0.27278...	0.50586...	0.1397166...	0.20931...	0.16323...	-0.02993698...	-0.3313928...	0.58384709...	0.54570039...	0.5434204...	?	0.525710...	1.0

Figura 29-Matriz Correlação do DataSet Hungarian.

Conclui-se que de facto não existem atributos com correlação forte o suficiente, ou seja, muito perto de 1 que possam ser retiradas por não trazerem informações relevantes. E, também, que não existem atributos com correlação negativa o suficiente, isto é, perto de -1 que permitam eliminar esses atributos por não terem qualquer relação com o atributo target, como se pode observar também pela figura abaixo.




Figura 30-Matriz de Correlação a cores do Dataset Hungarian.

3.3.4 Dataset Switzerland

Os dados gerais deste dataset foram conseguidos pela utilização do nodo Data Explorer:

Column	Exclude Column	Minimum	Maximum	Mean	Standard Deviation	Variance	Skewness	Kurtosis
age	☐	32	74	55.317	9.032	81.579	-0.497	-0.114
sex	☐	0	1	0.919	0.274	0.075	-3.102	7.748
cp	☐	1	4	3.699	0.689	0.474	-2.587	6.512
trestbps	☐	80	200	130.207	22.559	508.915	0.578	0.364
chol	☐	0	0	0	0	0	0	0
fbs	☐	0	1	0.104	0.309	0.095	2.676	5.383
restecg	☐	0	2	0.361	0.590	0.348	1.419	1.008
thalach	☐	60	182	121.557	25.977	674.827	-0.057	-0.226
exang	☐	0	1	0.443	0.499	0.249	0.234	-1.978
oldpeak	☐	-2	3	0.463	0.910	0.828	0.673	0.526
slope	☐	1	3	1.802	0.624	0.389	0.164	-0.524
ca	☐	1	2	1.600	0.548	0.300	-0.609	-3.333
thal	☐	3	7	5.789	1.731	2.998	-0.955	-0.986
num	☐	0	4	1.805	1.014	1.027	0.258	-0.771

Figura 31-Informação retirada do nodo Data Explorer no Dataset Switzerland.

Verifica-se primeiramente que o atributo *trestbps* tem um desvio padrão muito elevado assim como o atributo *thalach*, assim será necessário verificar a existência de outliers nos valores destas colunas. Seguidamente, verifica-se que o atributo target varia de 0 a 4 e, para estar de acordo com os dataset anteriores será necessário tratar esta informação.

Por fim, também se pode verificar que os valores do atributo *chol* serão, provavelmente, todos 0, por terem todos os valores das colunas da tabela acima a 0. Isto confirma-se ao observar o histograma obtido pelo nodo *Statistics*:




Figura 32- Informação retirada do nodo *Statistics* no Dataset Switzerland.

Assim, a coluna correspondente ao atributo *chol* terá de ser tratada.

Verifica-se também através desta tabela a existência de uma quantidade elevada de missing values nos atributos *ca* e *fbs*. Novamente, estas colunas terão de ser tratadas para este dataset também. Por outro lado, verifica-se que a distribuição da idade neste data set, varia entre 32 e 74.

Para verificar a existência de *outliers* neste dataset utiliza-se o nodo *Box Plot* mais uma vez, obtendo-se o seguinte gráfico de bigodes:




Figura 33- Boxplot e outliers obtidos para o Dataset Switzerland.

Existe no atributo *trestbps* um *outlier*. Ainda que não seja extremo, este outlier pode ser tratado mais a frente para não existir uma distribuição tão dispersa dos dados.

Por fim, também foram calculadas as correlações lineares entre cada atributo, como se pode observar na figura 34. Neste caso, existem valores que não foram possíveis calcular por serem colunas com os valores todos a 0, ou com *missing values*.

Row ID	D age	D sex	D cp	D trestbps	D chol	D fbs	D restecg	D thalach	D exang	D oldpeak	D slope	D ca	D thal	D num
age	1.0	-0.0490...	-0.033...	0.3688800...	?	0.1403...	0.2693591...	-0.286407...	-0.02225...	0.1511597...	0.09064...	0.58...	0.091553...	0.05068...
sex	-0.0490...	1.0	0.043...	-0.0840818...	?	0.0880...	0.0816893...	-0.121767...	0.085800...	-0.0453978...	-0.02367...	?	0.375035...	0.08985...
cp	-0.0332...	0.0430...	1.0	-0.0172384...	?	0.1432...	-0.236240...	-0.056341...	0.272818...	0.1787769...	0.06460...	-0.56...	0.430993...	0.23227...
trestbps	0.36888...	-0.0840...	-0.017...	1.0	?	0.0800...	0.1890163...	-0.207370...	0.129050...	0.0845565...	-0.14037...	0.43...	-0.16993...	0.13728...
chol	?	?	?	?	1.0	?	?	?	?	?	?	?	?	?
fbs	0.14031...	0.0880...	0.143...	0.0800028...	?	1.0	-0.009367...	0.1832307...	-0.15403...	0.2201893...	0.07823...	?	0.060644...	0.21092...
restecg	0.26935...	0.0816...	-0.236...	0.1890163...	?	-0.0093...	1.0	0.0155766...	-0.11863...	-0.0894198...	-0.08302...	0.21...	0.062690...	0.04546...
thalach	-0.2864...	-0.1217...	-0.056...	-0.2073702...	?	0.1832...	0.0155766...	1.0	-0.22204...	0.1705550...	-0.15553...	-0.55...	0.085427...	-0.2955...
exang	-0.0222...	0.0858...	0.272...	0.1290505...	?	-0.1540...	-0.118635...	-0.222045...	1.0	0.1729930...	0.19308...	-1.0	0.231956...	0.13208...
oldpeak	0.15115...	-0.0453...	0.178...	0.0845565...	?	0.2201...	-0.089419...	0.1705550...	0.172993...	1.0	-0.04415...	-0.51...	0.269453...	0.18678...
slope	0.09064...	-0.0236...	0.064...	-0.1403779...	?	0.0782...	-0.083021...	-0.155536...	0.193088...	-0.0441532...	1.0	-0.21...	-0.02725...	-0.0409...
ca	0.58619...	?	-0.560...	0.4360514...	?	?	0.2182178...	-0.557868...	-1.0	-0.5159691...	-0.21821...	1.0	?	-0.2721...
thal	0.09155...	0.3750...	0.430...	-0.1699390...	?	0.0606...	0.0626905...	0.0854271...	0.231956...	0.2694531...	-0.02725...	?	1.0	0.04410...
num	0.05068...	0.0898...	0.232...	0.1372885...	?	0.2109...	0.0454667...	-0.295579...	0.132089...	0.1867897...	-0.04099...	-0.27...	0.044100...	1.0

Figura 34- Matriz de Correlação do Dataset Switzerland.

Na matriz de cores abaixo, mostra-se a existência de correlações iguais a -1 entre si, ilustradas com a cor vermelha, no entanto, não estão relacionadas com o atributo target. Por outro lado, são colunas que vão ter de ser retiradas devido a *missing values* ou valores não definidos.




Figura 35- Matriz de Correlação a cores do Dataset Switzerland.

Verifica-se, no geral, a existência de vários missing values em diferentes argumentos e ainda que os datasets não possuem o mesmo número de colunas com informação de qualidade. Por outro lado, verifica-se que em todos os datasets o atributo idade varia entre cerca de 28 e 77.

Após a transformação dos dados foi também feita uma breve exploração dos dados, para mais uma vez testar a qualidade do tratamento de dados feito.

3.4 Preparação e Transformação dos dados

Através da exploração de dados, foi possível averiguar a melhor forma de tratar cada *dataset*, uma vez que estes contêm dados diferentes, e por esta razão, esses dados devem ser tratados também de formas distintas.

No geral, os nodos utilizados foram os seguintes: *Duplicate Row Filter*, *Numeric Outliers*, *Column Filter*, *Missing Values*, *Number to String*, *Rule Engine*.



Figura 36- Nodos *Duplicate Row Filter*, *Numeric Outliers*, *Missing Values*, *Number To String*, *Rule Engine* utilizados no tratamento dos dados.

3.4.1 Dataset Cleveland

Através da figura 37, pode observar-se os nodos implementados para o tratamento de dados do respetivo *dataset* em questão. Inicialmente começou-se por retirar eventuais valores duplicados, através do nodo *Duplicate Row Filter*, que poderiam ter uma influência negativa na previsão do modelo.

Posteriormente, através do nodo *Numeric Outliers* foi possível retirar outliers visualizados com auxílio do nodo *Box Plot*, aquando da exploração de dados.




Figura 37- Nodos implementados para o tratamento de dados no dataset Cleveland.

Deste modo, filtrou-se os atributos que continham *outliers*, neste caso, os atributos *trestbps*, *chol*, *thalach*, como consta na figura 38, substituindo esses valores por *missing values*.




Figura 38- Configuração do nodo Numeric Outliers no Dataset Cleveland.

De seguida, prosseguiu-se para o tratamento dos valores em falta (*missing values*), utilizando o nodo *Missing Value*.

Para abordar esta situação, existem duas maneiras de lidar com a ausência destes valores:

- Pela substituição de valores em falta, isto é, substituir os valores através de, por exemplo, média, moda, mediana ou média arredonda;
- Pela remoção das amostras dos valores em falta: normalmente ocorre a remoção de linhas que contêm 70-75% dos valores em falta. No entanto, a remoção das amostras pode levar à perda de informação.

Neste caso, foi utilizada a primeira opção para tratar os valores em falta das colunas *Ca* e *Thal*. Para determinar a melhor opção relativamente à substituição de valores pela média, mediana, moda ou média arredonda, foram testadas várias opções (Anexo- Tabela A) e constatou-se que a que tinha melhor desempenho nos diferentes modelos seria a substituição dos missing values pela moda (valor mais frequente).

Para este tratamento, foi utilizado o nodo *Missing Value*.




Figura 39 – Configuração do nodo Missing value no Dataset Cleveland.

Por último, recorreu-se ao nodo *Number to String* para colocar o atributo *num* em string .




Figura 40- Configuração do nodo Number to String.

Posteriormente, utilizou-se o nodo *Rule Engine*, onde ocorre a substituição dos dados da coluna *num* de “0”, “1”, “2”, “3” ou “4” para as strings “Não tem doença” ou “Tem doença”, como se ilustra abaixo.




Figura 41 – Configuração do nodo Rule Engine no Dataset Cleveland.

3.4.2 Dataset Long Beach

Do mesmo modo que o *dataset* anterior, através da figura 42, pode observar-se os nodos implementados para o tratamento de dados do respetivo *dataset* em questão. Primeiramente procedeu-se à remoção de eventuais valores duplicados que possam existir, com o auxílio do nodo *Duplicate Row Filter*.




Figura 42-Nodos implementados para o tratamento de dados no dataset LongBeach.

Posteriormente, prosseguiu-se para o tratamento de valores em falta. Através da visualização do *dataset*, constatou-se que existiam mais de 75% de valores em falta nas colunas *slope*, *ca* e *thal*, pelo que a decisão mais lógica a tomar foi remover essas colunas. Para tal, utilizou-se o nodo *Column Filter*.




Figura 43 – Configuração do nodo Column Filter no Dataset Long Beach.

Nas colunas *chol*, *thalach*, *oldpeak*, *trestbps*, *fbs*, *exang*, *restecg* também existiam valores em falta, pelo que, considerando os testes feitos no Anexo (como referido anteriormente), decidiu-se através do nodo *Missing Value*, tratar os valores contínuos com a média arredondada e os categóricos com a moda, para os casos dos modelos Árvores de Decisão, Gradient Boosting e Redes Neurais. Para o modelo Random Forest, como se pode observar na tabela 1 do anexo, o melhor desempenho consegue-se quando os missing values são substituídos pela moda e a média, então os missing values foram substituídos dessa forma.

Por último, foi elaborado o mesmo procedimento do *dataset* anterior, utilizando o nodo *Number to String* para colocar o atributo *num* em string, visível na figura 44 e o nodo Rule Engine, onde ocorre a substituição dos dados da coluna *num* para as strings “Não tem doença” ou “Tem doença”.




Figura 44 – Configuração do nodo Number to String no Dataset LongBeach




Figura 45 – Configuração do nodo Rule Engine no Dataset LongBeach.

3.4.3 Dataset Hungarian

Mais uma vez, através da figura 46, pode observar-se os nodos implementados para o tratamento de dados do respetivo dataset. Inicialmente, utilizou-se o nodo *Duplicate Row Filter* para remover eventuais linhas duplicadas.




Figura 46-Nodos implementados para o tratamento de dados no dataset Hungarian.

De seguida, recorreu-se ao tratamento dos outliers expressos no gráfico resultante da utilização do nodo *Box Plot*. Com efeito, filtrou-se os atributos que apresentavam outliers, pelo nome *Numeric Outliers*, e substituiu-se esses valores, para serem tratados posteriormente.




Figura 47 – Configuração do nodo Numeric Outliers no Dataset Hungarian.

Posteriormente, seguiu-se para o tratamento de *missing values*. Com o auxílio dos nodos de exploração de dados, observou-se mais uma vez que as colunas *slope*, *ca* e *thal* apresentavam demasiados valores ausentes, pelo que se decidiu proceder à sua remoção, utilizando o nodo *Column Filter*.




Figura 48 – Configuração do nodo *Column Filter* no Dataset Hungarian

Em relação às restantes colunas, existiam valores ausentes nas colunas *trestbps*, *chol*, *thalach*, *exang*, *restcg* e *fbs*. Com base nos diversos testes feito, foi possível escolher a moda e a média arredondada, novamente, para os modelos Árvores de Decisão, Gradient Boosting e Redes Neurais. Quanto ao modelo Random Forest, os dados categóricos foram também substituídos pela moda, mas os dados contínuos substituídos pela média.

Finalmente, implementou-se o nodo *Number to String* e *Rule Engine*, com o mesmo intuito que os *datasets* anteriores.




Figura 49 – Configuração do nodo *Number to String* no Dataset Hungarian

Neste caso, o atributo *num* tem valores apenas de 0 e 1, pelo que só será necessário transformar esses valores nas strings apresentadas abaixo.




Figura 50 – Configuração do nodo *Rule Engine* no Dataset Hungarian

3.4.4 Dataset Switzerland

De modo similar, através da figura 51, pode observar-se os nodos implementados para o tratamento de dados do *dataset* em questão. Procedeu-se igualmente à remoção de eventuais valores duplicados, com recurso ao nodo *Duplicate Row Filter*.




Figura 51-Nodos implementados para o tratamento de dados no dataset Switzerland

Posteriormente, desejou-se remover os *outliers* visualizados aquando da exploração dos dados. Para isso, recorreu-se ao nodo *Numeric Outliers*, onde esses valores foram substituídos por *missing values* que foram tratados mais à frente.




Figura 52 – Configuração do nodo *Numeric Outliers* no Dataset Switzerland.

Tendo em vista o tratamento de *missing values*, verificou-se mais uma vez que existiam certas colunas onde existia mais de 75% de ausência de valores (colunas *chol*, *slope*, *ca* e *thal*). Ainda que a coluna *chol* tivesse todos os seus valores a 0, tendo em conta que o objetivo é criar um dataset total, esta coluna não foi removida, mas terá outro tratamento a seguir. Pelo contrário as colunas *slope*, *ca* e *thal*, não só no *dataset* Switzerland mas também no *dataset* total que se pretende criar, resultariam novamente em cerca de 70% dos *missing values*, já que outros *datasets*

também apresentam missing values nestes atributos. Assim, removeram-se essas colunas, utilizando o nodo *Column Filter*.




Figura 53 – Configuração do nodo *Column Filter* no Dataset *Switzerland*.

Em relações às restantes colunas, verificou-se a existência de valores ausentes em *trestbps*, *fbs*, *restecg*, *thalach*, *exang* e *oldpeak*. Após vários testes, foi tomada a decisão de substituir os valores ausentes pela média arredondada e pela moda no nodo *Missing Values*, mais uma vez nos modelos Árvores de Decisão, Gradient Boosting e Redes Neurais. No modelo Random Forest, como se pode observar na tabela 1 do Anexo, a melhor escolha foi substituir estes valores pela moda e média.

Finalmente, implementou-se o nodo *Number to String* (passando mais uma vez o atributo *num* para string) e o nodo *Rule Engine*, para alterar os nomes dos dados da coluna *num*, como se pode observar abaixo:




Figura 54 – Configuração do nodo *Number to String* no Dataset *Switzerland*.

Assim, os dados do tipo inteiro “0” e “1”, “2”, “3”, “4” passaram a, respetivamente, “Não tem doença” e “Tem doença”.






Figura 55- Configuração do nodo *Rule Engine* no Dataset *Switzerland*.

Verificou-se, nos 4 *datasets*, que em vários atributos a maioria dos registos tinham *missing values* e, por esse facto decidiu eliminar-se estas colunas, nomeadamente, as colunas *ca*, *slope* e *thal*. Após esta eliminação verificou-se também que alguns dos registos continham ainda alguns *missing values* mas que eram passíveis de serem substituídos por valores como a média ou moda, de forma a combater a perda de informação. Por outro lado, não foi eliminada a coluna *chol* do último *dataset*, os valores desta coluna irão ser substituídos pela média ou mediana dos valores da coluna no dataset total que irá ser formado.

Assim, após o tratamento em separado para cada *dataset*, foi feita a concatenação dos quatro, recorrendo ao nodo *Concatenate*, configurando-o de modo a ser utilizada a interseção de colunas que são as mesmas em todos os *datasets*, obtendo-se um *dataset* com 920 registos.



Posteriormente, com o *dataset* total foram então substituídos os valores de colesterol a 0, provenientes do dataset Switzerland com a média ou mediana dos restantes valores. Para isso foi utilizado o nodo Column Expressions para tornar estes valores a 0 *missing values*, como se pode ver na figura seguinte:



Por fim, para dar valores aos missing values criados, utilizou-se o nodo Missing values e selecionou-se qual a substituição pretendida. Dependendo dos modelos, a substituição escolhida diferiu: para o modelo Árvore de Decisão, substituir com a média ou mediana, mostrava o mesmo resultado de accuracy, pelo que se escolheu utilizar a média; para o modelo Random Forest escolheu-se o valor mediana por mostrar melhor desempenho; no modelo Gradient Boosting, a média mostrou trazer melhor desempenho e, finalmente para o modelo das Redes Neurais




Figura 58-Fluxo criado para preparação de dados do dataset total.

Artificiais utilizou-se a média dos valores da coluna. Assim, após a concatenação dos datasets criou-se um fluxo com estes dois nodos, como se pode verificar pela figura abaixo:

É de ressaltar que nos modelos de redes neurais, é aconselhável normalizar os dados. Esta etapa tem como finalidade adaptar os dados de entrada à faixa dinâmica das funções de ativação da rede neuronal, aumentando assim a estabilidade das redes.

Para tal, implementou-se o nodo *Normalizer*, no caso do modelo das redes neurais.



Figura 59-Nodo Normalizer.

3.5 Partição de dados e Criação dos Modelos

3.5.1 Partição de dados

Antes de se desenvolver os modelos, é necessário existirem dois *datasets*: o *dataset* de treino e o *dataset* de teste. Com o *dataset* de treino cria-se o modelo temporário e, através do *dataset* de teste, avalia-se o desempenho do modelo.

Assim, procede-se à partição aleatória dos dados totais de entrada para os dois *datasets*, utilizando o nodo *Partitioning*. Pode-se ainda selecionar a percentagem relativa que se pretende para cada um, sendo que neste caso foi selecionado 75% dos dados para treino e consequentemente 25%

dos dados para teste. Como visualizado na figura 60, este nodo apresenta duas saídas, sendo que a primeira saída corresponde aos dados de treino e a segunda aos dados de teste.




Figura 60- Nodo Partiotioning e a sua configuração.

Selecionou-se a configuração random seed, com o número 2022, para os resultados serem os mesmos, nas várias tentativas (com igual configuração dos nodos). A seguir mostra-se o desenvolvimento de quatro modelos, utilizando as técnicas de Árvores de Decisão, Random Forest, Gadiant Boosting e Redes Neurais Artificiais

3.5.2 Árvores de decisão

Para se proceder à construção do modelo de árvore de decisão é necessário a implementação de 2 nodos: *Decision Tree Learner*, *Decision Tree Predictor*.

Assim, implementou-se o nodo *Decision Tree Learner* que irá produzir a uma árvore de decisão de classificação na memória principal. A entrada deste nodo será a primeira saída do nodo *Partitioning* ou seja, a saída correspondente aos dados de treino. Configurou-se ainda o nodo, selecionando para o atributo target o parâmetro *num*.




Figura 61- Nodo Decision Tree Learner e a sua configuração.

Posteriormente, implementou-se o nodo Decision Tree Predictor. Este nodo utiliza uma árvore de decisão já existente (árvore de decisão produzida pelo nodo Decision Tree Learner) para prever o parâmetro pretendido para novos padrões. A primeira entrada deste nodo será assim a saída do nodo *Decision Tree Learner* e a segunda entrada será a segunda saída do nodo *Partitioning* ou seja, a saída correspondente aos dados de teste.



Figura 62- Nodo Decision Tree Predictor.

Assim, forma-se o seguinte Fluxo:




Figura 63- Modelo Decision Tree Learner.

3.5.3 Random Forest

Depois de feita a partição dos dados em dados de treino e dados de teste, os dados de teste vão ser usados na formulação do modelo. Ou seja, vão ser estes dados que vão ser usados para o

modelo aprender. Assim, ligou-se o output do nodo *Partitioning* correspondente aos dados de treino ao nodo Random Forest Learner. Foi selecionada a configuração *Static Random Seed* com o número 2022, para os resultados obtidos nas várias tentativas serem iguais.



Figura 64- Nodo do Random Forest Learner

Posteriormente, o modelo criado no nodo anterior foi ligado ao nodo Random Forest Predictor, assim como o output correspondente aos dados de teste saído do nodo Partitioning.



Figura 65- Nodo Random Forest Predictor.

Este nodo vai prever o atributo target *num* dos dados de teste segundo o modelo criado no nodo Random Forest Learner. O Fluxo no total apresenta-se da seguinte forma:




Figura 66- Fluxo do Modelo Random Forest Learner.

Assim, o modelo foi criado através dos dados de treino e testado com os dados de teste.

3.5.4 Gradient Boosting

Após a partição dos dados de modelo, procedeu-se também à construção do modelo *Gradient Boosting*. Para tal, foi necessária a execução dos nodos Gradient Boosted Trees Learner e Gradient Boosted Trees Predictor.

Primeiramente, ligou-se o output do Partitioning correspondente aos dados de treino ao nodo Gradiente Boosted Trees Learner.



Figura 67- Nodo Gradient Boosted Learner.

Após diversas tentativas relativas à configuração do nodo acima, percebeu-se que para um melhor desempenho do modelo, dever-se-ia limitar o número de níveis da árvore para 4, o número de modelos a 100 e a taxa de aprendizagem deveria corresponder a 0,1 (10%), como demonstrado na figura 68.

Tree Options	
☒ Limit number of levels (tree depth)	4
Boosting Options	
Number of models	100
Learning rate	0,1

Figura 68- Configuração do nodo Gradient Boosted Trees Learner.

Posteriormente, o modelo criado no nodo anterior foi ligado ao nodo Gradient Boosted Trees Predictor, assim como o output correspondente aos dados de teste saído do nodo Partitioning.




Figura 69- Nodo Gradient Boosted Tree Predicted.

Assim, forma-se o seguinte Fluxo, onde o modelo irá prever o target num com os dados de treino e os dados de testes segmentados com o nodo *Partitioning*.




Figura 70- Modelo Gradient Boosting.

3.5.5 Redes Neurais Artificiais

Após efetuar a normalização dos dados e após a partição construiu-se o modelo de rede neuronal onde são necessários 2 nodos: *RProp MLP Learner* e o *MultiLayerPerceptron Predictor*, interligando-se o primeiro output do nodo *Partitioning*, ou seja, liga-se a saída correspondente aos dados de treino ao nodo *RProp MLP Learner*.

O nodo implementa o algoritmo *RProp* para redes feedforward multicamadas.

Procedeu-se, então, à configuração do nodo com um número máximo de iterações de 100 que corresponde ao número de iterações de aprendizagem; um número de camadas ocultas de 11, ou seja, existem 11 camadas ocultas na arquitetura da rede neuronal e com o número de neurónios ocultos por camada oculta de 15.

Seleciona-se também a coluna da classe *num*, ou seja, seleciona-se a coluna que contém o atributo *target* e não ignoramos os missing values por terem sido tratados antes. Por último foi escolhida a configuração *Use seed for random initialization* com o número 2022.




Figura 71- Nodo *RProp MLP Learner* e a sua configuração.

Posteriormente implementou-se o nodo *MultiLayerPerceptron Predictor* em que a sua primeira entrada será a saída do nodo *RProp MLP Learner*, ou seja, e a segunda entrada será a saída correspondente aos dados de teste, ou seja, a segunda saída do nodo *Partitioning*.




Figura 72- Nodo MultiLayerPerceptron Predictor.

A função deste é calcular os valores de saída do atributo target *num* esperados com base em um modelo MultiLayerPerceptron treinado fornecido do nodo anterior. O Fluxo no total apresenta-se da seguinte forma:




Figura 73- Modelo Redes Neurais.

3.6 Avaliação do desempenho dos modelos

Para a avaliação do desempenho dos modelos utilizaram-se nodos que permitissem o cálculo de algumas métricas de avaliação como por exemplo a matriz de confusão e, conseqüentemente, a *Accuracy*, a sensibilidade e especificidade, o coeficiente de *Cohen*, a curva ROC e ainda a *F-Measure*. Assim foram utilizados os nodos Scorer (Java Script) e ROC Curve:



Figura 74- Nodos Scorer (Java Script) e ROC Curve utilizados na avaliação dos modelos.

A seguir mostra-se detalhadamente a avaliação do desempenho de cada modelo desenvolvido.

3.6.1 Árvores de decisão

Para uma análise da qualidade do modelo das Árvores de Decisão, implementou-se o nodo *Scorer (JavaScript)* e o nodo *ROC Curve*.

O nodo *Scorer* faz a comparação dos valores reais com os valores previstos pelo modelo para o parâmetro pretendido. Neste caso será a previsão se o paciente apresenta ou não doença.

Procedeu-se à configuração do nodo, seleccionando-se para a primeira coluna a comparar o parâmetro num e para a segunda coluna o parâmetro num previsto.

De seguida, pode visualizar-se a matriz de confusão, onde os valores da primeira coluna seleccionada estão representados nas linhas e os valores da segunda coluna nas colunas da matriz.

Scorer View
Confusion Matrix

	Nao tem doença (Predicted)	Tem doença (Predicted)	
Nao tem doença (Actual)	75	26	74.26%
Tem doença (Actual)	26	103	79.84%
	74.26%	79.84%	

Overall Statistics

Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
77.39%	22.61%	0.541	178	52

Figura 75- Matriz de Confusão do Modelo Árvores de Decisão.

Através da análise da matriz pode inferir-se sobre o sucesso no que diz respeito às previsões do modelo. Assim, verifica-se que efetivamente dos 101 (75+26) casos previstos como não apresenta doença, apenas 26 se encontram incorretamente diagnosticados. Já dos 129 previstos como não apresenta doença, apenas 26 se encontram incorretamente diagnosticados.

Pode ainda observar-se uma análise estatística do modelo através de parâmetros como a *Accuracy* (%), erro total (%), coeficiente kappa de Cohen e o número de casos corretamente e incorretamente previstos.

Assim observa-se que o modelo tem um valor de *Accuracy* igual a 77.39%, o que significa que a soma do número de valores previstos de verdadeiros positivos e verdadeiros negativos sobre a soma do número de valores totais previstos é igual a 77.39%. Sabe-se ainda que ocorre um erro total de 22,61%.

Verifica-se também que o coeficiente kappa de Cohen é igual a 0.541, sendo que teoricamente quanto mais próximo de 1 maior a concordância dos dados analisados das duas colunas da matriz confusão.

Por fim, observa-se que o número total de pacientes corretamente e incorretamente classificados é igual a 178 e 52, respetivamente.

Ainda neste nodo, pode-se proceder à análise da tabela de estatísticas do modelo.

Row ID	True Po...	False P...	True N...	False N...	D Recall	D Precision	D Sensitivity	D Specificity	D F-meas...
Nao tem doença	75	26	103	26	0.743	0.743	0.743	0.798	0.743
Tem doença	103	26	75	26	0.798	0.798	0.798	0.743	0.798

Figura 76- Matriz de estatísticas do modelo Árvores de Decisão.

Através da análise da tabela representada na figura 76, acrescenta-se à informação vista anteriormente a análise da precisão, sensibilidade, especificidade e F-measure.

Verifica-se ainda que para os casos de não apresentação de doença existe uma precisão da previsão de 0.743 e para os casos de apresentação de doença uma precisão de previsão de 0.798, tendo-se desta forma, previsto mais adequadamente os casos de apresentação de doença. Relativamente à sensibilidade do modelo verifica-se uma maior sensibilidade para os casos de não apresentação de doença correspondendo a 0.798 do que para os casos de apresentação de doença correspondendo a 0.743 e relativamente à especificidade os valores estão trocados, ou seja 0.743 para os casos de não apresentação de doença e 0.798 para os casos de apresentação de doença.

Este facto acontece porque teoricamente a sensibilidade corresponde à probabilidade de resultado positivo nos doentes e a especificidade corresponde à probabilidade de resultado negativo nos não doentes.

Por fim, relativamente ao *F-measure*, verificamos que apresenta também ele valores aceitáveis, sendo que este é uma métrica melhor que a *Accuracy*, principalmente nos casos onde os falsos positivos e os falsos negativos apresentam impactos diferentes para o modelo.

Para uma análise mais completa da qualidade do modelo, implementou-se ainda o nodo ROC Curve.

Este nodo, como referido na secção preliminares, permite a visualização da curva de ROC que demonstra o desempenho de um modelo de classificação em diferentes limites através da relação entre a taxa de verdadeiros positivos e a taxa de falsos positivos.




Figura 77- Curvas ROC do modelo Árvores de Decisão.

Por observação da figura 77, verifica-se que as curvas que se aproximam minimamente à curva ROC padrão são, por exemplo, a curva equivalente à relação entre o target *num* e o atributo *cp* e *exang*.

Assim, conclui-se que estas curvas apresentam valores previstos corretamente classificados ao contrário das restantes curvas apresentadas na figura 77, que se afastam demasiado da curva padrão ROC e se aproximam mais da linha aleatória gerada para a comparação dos resultados.

3.6.2 Random Forest

Após o desenvolvimento do modelo e utilizado o nodo *Predictor*, utilizou-se o nodo *Scorer* para poder analisar o desempenho do modelo de Random Forest, obtendo-se a seguinte matriz de confusão.

Scorer View

Confusion Matrix

	Nao tem doença (Predicted)	Tem doença (Predicted)	
Nao tem doença (Actual)	74	27	73.27%
Tem doença (Actual)	14	115	89.15%
	84.09%	80.99%	

Overall Statistics

Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
82.17%	17.83%	0.633	189	41

Figura 78- Matriz de Confusão do Modelo Random Forest.

Como se pode verificar na figura acima, 74 casos com diagnóstico “Não tem doença” foram classificados corretamente. Da mesma forma, 115 casos de diagnóstico “Tem doença” também foram classificados corretamente.

Por outro lado, foram incorretamente classificados 41 (14+27) casos incorretamente. Assim, a *Accuracy*, que corresponde ao rácio de classificações corretas pelo total de casos, obtida foi de 82,17%.

Na figura acima, também se pode analisar o erro geral obtido, neste caso, 17,83% e o coeficiente Cohen de 0,633. Este coeficiente não está muito próximo de 1, que representaria o modelo ideal.

Ainda se podem retirar estas informações em forma de tabela do nodo *Scorer*:

Row ID	I True Positives	I False Positives	I True Negatives	I False Negatives	D Recall	D Precision	D Sensitivity	D Specificity	D F-measure
Nao tem doença	74	14	115	27	0.733	0.841	0.733	0.891	0.783
Tem doença	115	27	74	14	0.891	0.81	0.891	0.733	0.849

Figura 79- Matriz de estatísticas do modelo *Random Forest*.

Nesta tabela, pode analisar-se os valores de precisão, sensibilidade, especificidade e ainda *F-Measure*. Neste caso, verifica-se uma sensibilidade na previsão de casos positivos. Por outro lado, a especificidade e a precisão mostram-se maiores para os casos negativos. Ainda se pode observar um bom *F-Measure* na classificação de casos de diagnóstico positivo da doença e um razoável *F-Measure* na classificação de diagnóstico negativo da doença.

Por outro lado, também se podem analisar as curvas ROC através do nodo *ROC Curve*, obtendo-se neste caso, uma curva para cada relação entre os atributos e o atributo target, como se pode ver na figura 80.




Figura 80- Curvas ROC do modelo *Random Forest*.

No geral, verifica-se que algumas curvas se assemelham à curva ROC ideal, como por exemplo, a curva correspondente à relação entre o target num e o atributo *cp* e *exang*. A curva ROC, como referido acima, analisa a relação entre a taxa de verdadeiros positivos e a taxa de falsos positivos. Os restantes atributos não mostram tanta semelhança em relação à mesma curva ótima. Isto mostra que um número elevado de valores do conjunto caso de teste foi incorretamente classificado.

3.6.3 Gradient Boosting

Após a construção do modelo, utilizou-se o nodo *Scorer* para analisar o seu desempenho do Modelo de Gradient Boosting. Obteve-se a seguinte matriz de confusão.

Scorer View
Confusion Matrix

	Nao tem doença (Predicted)	Tem doença (Predicted)	
Nao tem doença (Actual)	75	26	74.26%
Tem doença (Actual)	17	112	86.82%
	81.52%	81.16%	

Overall Statistics

Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
81.30%	18.70%	0.617	187	43

Figura 81- Matriz de confusão do modelo de Gradient Boosting.

Como se pode verificar na figura acima, 75 caso com diagnóstico “Não tem doença” foram classificados corretamente. Da mesma forma, 112 casos de diagnóstico “Tem doença” também foram classificados corretamente.

Por outro lado, foram incorretamente classificados 43 (17+26) casos incorretamente. Assim, a *Accuracy*, que corresponde ao rácio de classificações corretas pelo total de casos, obtida foi de 81,30%.

Na figura acima, também se pode analisar o erro geral obtido, neste caso, 18,70% . Verifica-se também que o coeficiente kappa de Cohen é igual a 0.617, sendo que teoricamente quanto mais próximo de 1 maior a concordância dos dados analisados das duas colunas da matriz confusão.

Ainda se podem retirar estas informações em forma de tabela do nodo *Scorer*:

Row ID	I True Positives	I False Positives	I True Negatives	I False Negatives	D Recall	D Precision	D Sensitivity	D Specificity	D F-measure
Nao tem doença	75	17	112	26	0.743	0.815	0.743	0.868	0.777
Tem doença	112	26	75	17	0.868	0.812	0.868	0.743	0.839

Figura 82- Matriz de estatísticas do modelo Gradient Boosting .

Nesta tabela, pode analisar-se os valores de precisão, sensibilidade, especificidade e ainda *F-Measure*. Neste caso, verifica-se uma maior precisão e uma maior especificidade para os casos onde não há doença. Por outro lado, existe uma maior sensibilidade nos casos em que há doença.

Ainda se pode observar um bom *F-Measure* na classificação de casos de diagnóstico positivo da doença e um razoável *F-Measure* na classificação de diagnóstico negativo da doença.

Por outro lado, também se pode recorrer às curvas ROC através do nodo *ROC Curve*, obtendo-se neste caso, uma curva para cada relação entre os atributos e o target *num*, como se pode ver na figura 83.




Figura 83 – Curva ROC do modelo Gradient Boosted.

Através da análise da figura acima, é possível observar que existem algumas curvas que se assemelham à curva ROC ideal, nomeadamente a curva relação entre o target *num* e o atributo *cp* e *exang*.

A curva ROC analisa a relação entre a taxa de verdadeiros positivos e a taxa de falsos positivos. Deste modo, quando maior for o declive da curva, melhor será o desempenho do modelo.

Relativamente aos restantes atributos, as curvas que os relacionam ao target *num*, não são muito semelhantes à ideal, pelo que pode inferir-se que houve uma maior previsão incorreta de valores.

3.6.4 Redes Neurais Artificiais

Para analisar o desempenho do modelo de Redes Neurais Artificiais, utilizou-se o nodo *Scorer* que permite a obtenção da matriz de confusão representada na figura 84.

Scorer View
Confusion Matrix

	Nao tem doença (Predicted)	Tem doença (Predicted)	
Nao tem doença (Actual)	77	24	76.24%
Tem doença (Actual)	23	106	82.17%
	77.00%	81.54%	

Overall Statistics

Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
79.57%	20.43%	0.585	183	47

Figura 84 – Matriz de confusão do modelo de Redes Neurais.

Através da figura em cima consegue-se concluir que existem 183 casos que foram corretamente classificados dos quais 77 casos com diagnóstico Não tem doença e 106 com diagnóstico Tem doença.

No entanto, 47 casos foram classificados de forma incorreta. Assim, a *Accuracy*, que corresponde ao rácio corresponde ao rácio de classificações corretas pelo total de casos, obtida foi de 79,57%.

Na matriz de confusão também se observa um erro de geral obtido de 20,43% e um coeficiente de Cohen igual a 0,585, não muito próximo de 1 logo não há muita concordância entre os dados analisados.

Ainda se podem retirar estas informações em forma de tabela do nodo *Scorer* onde podemos obter informação sobre a precisão, sensibilidade, especificidade e F-measure.

Row ID	I True Po...	I False P...	I True N...	I False N...	D Recall	D Precision	D Sensitivity	D Specificity	D F-meas...
Nao tem doença	77	23	106	24	0.762	0.77	0.762	0.822	0.766
Tem doença	106	24	77	23	0.822	0.815	0.822	0.762	0.819

Figura 85- Matriz de estatísticas do modelo Redes Neurais.

Através desta verifica-se que a precisão dos casos que não tem doença é de 0,77 e os que tem doença de 0,815, ou seja, os valores obtidos estão relativamente próximos uns dos outros demonstrando coesão nos dados obtidos. A sensibilidade é de 0,762 logo há 76,2% de resultados positivos entre as pessoas que Tem doença e 82,2% de resultados positivos entre as pessoas que Não tem doença. Em relação à especificidade consegue-se concluir que 82,2% do teste ser

negativo nos indivíduos que Não tem doença e 76,2% do teste ser negativo nos indivíduos que Tem doença.

O valor de F-measure, mais conhecido por F-score, para os casos em que “Não tem doença” é de 0,766 e que “Tem doença” de 0,819 o que são considerados valores razoáveis pois quanto mais próximo de 1 mais baixo será o número de falsos positivos e falsos negativos.

De modo a obter uma análise mais completa implementou-se o nodo ROC curve onde se obtém o seguinte gráfico:




Figura 86-Curvas ROC do modelo de Redes Neurais.

Verifica-se que algumas curvas se assemelham à curva ROC ideal como a curva correspondente à relação entre o target *num* e o atributo *exang* e *cp*. Nestes atributos, a taxa de verdadeiros positivos é bastante superior a taxa de falsos positivos sendo este facto positivo para o modelo. As curvas dos atributos *fbs*, *restecg*, *sex*, *age*, *oldpeak* e *trestbps* são semelhantes à curva do classificador aleatório (a curva preta) em que a taxa de verdadeiros positivos é quase igual à taxa de falsos positivos. A curva do atributo *thalach* corresponde a uma taxa de falsos positivos bastante superior à taxa de verdadeiros positivos demonstrando assim que um número elevado de valores do conjunto caso de teste foi incorretamente classificado.

3.6.5 Escolha do Modelo

Tendo em conta todas as métricas analisadas em todos os modelos, fez-se uma recolha dos dados mais importantes, ilustrada na tabela abaixo, para poder ser feita uma melhor comparação dos modelos.

Tabela 1 – Comparação das métricas de avaliação dos modelos criados

Modelo / Métricas	Accuracy (%)	Erro (%)	Coef. Cohen	F-Measure		Especificidade		Sensibilidade		Precisão	
				TD	NTD	TD	NTD	TD	NTD	TD	NTD
Árvores Decisão	77,39	22,61	0,541	0,798	0,743	0,743	0,798	0,743	0,798	0,743	0,798
Random Forest	82,17	17,83	0,633	0,849	0,783	0,733	0,891	0,891	0,733	0,81	0,841
Gradient Boosting	81,30	18,70	0,617	0,839	0,777	0,743	0,868	0,868	0,743	0,812	0,815
R.Neuronais Artificiais	79,57	20,43	0,585	0,819	0,766	0,762	0,822	0,822	0,762	0,815	0,77
TD – Ter Doença; NTD – Não Ter Doença											

O algoritmo Random Forest demonstrou exatidão de 82,17%, o Gradient Boosting de 81,30%, as Redes Neurais Artificiais de 79,57% e as Árvores Decisão de 77,39%. No geral, todos os algoritmos se apresentam aptos a fazer o diagnóstico da doença em pacientes entre os 28 e os 77 anos, com bastante precisão e exatidão. Contudo, o algoritmo Random Forest apresenta melhores resultados para todas as métricas testadas exceto para a sensibilidade do diagnóstico de não ter doença/ especificidade de ter doença e ainda para a precisão de ter diagnóstico doença.

A sua *accuracy*, coeficiente de *cohen* e *f-measure* são as que mais se aproximam do modelo ideal e por isso poderia ser o modelo selecionado. Por outro lado, de acordo com a secção preliminares, este modelo evita o fenómeno de overfitting numa possível previsão. Ainda assim, o modelo poderia melhorar o seu desempenho quando fornecido de mais dados.

Assim, pode concluir-se que o modelo no qual se usou a técnica Random Forest apresenta melhores resultados em algumas métricas quando comparado aos outros modelos testados e poderia ser uma boa escolha, ainda que os outros modelos também tenham apresentado métricas de valor semelhante.

4. Conclusão

No presente trabalho, foi apresentado o desenvolvimento de um sistema de aprendizagem automática capaz de prever a existência ou não de doença cardíaca em doentes. Com efeito foram criados 4 modelos diferentes para depois ser avaliado e comparado o seu desempenho. Os modelos desenvolvidos foram baseados no algoritmo Random Forest, o Gradient Boosting, as Redes Neurais Artificiais e as Árvores Decisão. Os presentes métodos visam resolver problemas de classificação, pelo que foram os escolhidos para a elaboração deste trabalho.

Feito o carregamento dos datasets fornecidos, procedeu-se à exploração dos dados através de uma análise estatística, tendo em conta a análise de histogramas, distribuição e correlações e métricas estatísticas como o desvio padrão na análise de dados foi determinada a melhor forma de tratar cada dataset.

Posteriormente, foram tratados os dados utilizando nodos como *Duplicate Row Filter* para tratar de dados eventualmente duplicados, *Numeric Outliers* para remover outliers, *Missing Value* para tratar os valores ausentes, substituindo-os do modo mais adequado, *Number to String* para converter o target *num* numa string e por fim o *Rule Engine* para substituir os valores “0”, “1”, “2”, “3”, “4” pelo pretendido “Tem doença” ou “Não tem doença”.

Depois de tratados, os dados foram segmentados com auxílio do nodo *Partitioning* em dados de treino e dados de teste. De seguida, foram submetidos aos 4 modelos descritos.

Adiante, com o nodo *Scorer* (Java Script) foram avaliados os modelos, utilizando várias métricas de avaliação, tais como a matriz de confusão, e consequentemente a *accuracy*, a sensibilidade e especificidade, o coeficiente de *Cohen*, e ainda a *F-Measure*. Utilizando o nodo ROC curva, também foi analisada a curva ROC.

Finalmente, foram comparados os desempenhos de cada modelo em que o algoritmo Random Forest demonstrou exatidão de 82,17%, o Gradient Boosting de 80,43%, as Redes Neurais Artificiais de 79,57% e as Árvores Decisão de 77,39%.

5. Referências

- [1] S. Angra and S. Ahuja, "Machine learning and its applications: A review," *2017 International Conference on Big Data Analytics and Computational Intelligence (ICBDAC)*, 2017, pp. 57-60, doi: 10.1109/ICBDACI.2017.8070809. Disponível em: <https://ieeexplore.ieee.org/document/8070809>
- [2] IBM (2022). "Learn the pros and cons of using decision trees for data mining and knowledge discovery tasks". What is a Decision Tree?". Disponível em: <https://www.ibm.com/topics/decision-trees>. (acedido a 28 de dezembro 2022).
- [3] JAVA OINT (2022). "Random Forest Algorithm". Disponível em: <https://www.javatpoint.com/machine-learning-random-forest-algorithm>. (acedido a 28 de dezembro 2022).
- [4] Deng, Haowen & Zhou, Youyou & Wang, Lin & Zhang, Cheng. (2021). "Ensemble learning for the early prediction of neonatal jaundice with genetic features". *BMC Medical Informatics and Decision Making*. Disponível em: https://www.researchgate.net/figure/The-architecture-of-Gradient-Boosting-Decision-Tree_fig2_356698772 (acedido a 30 de dezembro 2022).
- [5] Hardesty, Larry, "Explained: Neural networks", *MIT News Office*, Massachusetts Institute of Technology, April 14, 2017. <https://news.mit.edu/2017/explained-neural-networks-deep-learning-0414> (acedido a 30 de dezembro 2022).
- [6] Dhvani M Vaidya, Akshit J Dhruv, "Data-science to predict Entrepreneurial Skills based on Profession", *2021 International Conference on Artificial Intelligence and Machine Vision (AIMV)*, pp.1-5, 2021. Disponível em: <https://ieeexplore.ieee.org/document/9141187>
- [7] Das Sumit, Roy, Nabamita, et al. "Applications of Artificial Intelligence in Machine Learning: Review and Prospect", *International Journal of Computer Applications* (0975 – 8887), Volume 115 – No. 9, April 2015
- [8] Kurana, Parveen, "Uses of Histograms in Machine Learning", jan 30, 2021. <https://prvnx10.medium.com/uses-of-histograms-in-machine-learning-e209bad36cd2>. (acedido a 27 de dezembro 2022).
- [9] Sameer, Ameer. (2015). "Normal Distribution". Doi: 10.13140/RG.2.1.1952.7760. Disponível em: https://www.researchgate.net/publication/289239035_Normal_Distribution (acedido a 24 de dezembro 2022).
- [10] Semi Koen, «Architecting a Machine Learning Pipeline», *Towards Data Science*, 2019. <https://towardsdatascience.com/architecting-a-machine-learning-pipeline-a847f094d1c7>. (acedido a 23 de dezembro 2022).
- [11] A. Posoldova, "Machine Learning Pipelines: From Research to Production," in *IEEE Potentials*, vol. 39, no. 6, pp. 38-42, Nov.-Dec. 2020, doi: 10.1109/MPOT.2020.3016280. Disponível em: <https://ieeexplore.ieee.org/document/9258455>
- [12] A. Amidi e S. Amidi, «Machine Learning tips and tricks cheatsheet». <https://stanford.edu/~shervine/teaching/cs-229/cheatsheet-machine-learning-tips-and-tricks>. (acedido a 1 de janeiro 2022).
- [13] Stephen Allwright, «How to interpret F1 score (simply explained)», *Ghost & Krabi*, 2022. (acedido a 1 de janeiro 2022)

6. Anexo




Figura 87- Pipeline criado para o desenvolvimento de um modelo de Árvores de Decisão.

Tabela A- Testes nos diferentes modelos para substituir missing-values.

	Moda+ Média Arredondada (%)	Moda+ Média (%)	Mediana+ Média Arredondada(%)	Mediana+ Média (%)
Árvores de Decisão	77.39	77.39	77.39	77.39
Random Forest	81.74	82.17	81.74	82.17
Gradient Boosted	81.30	80.43	81.30	80.43
Redes neurais	79.57	76.52	79.57	76.52