

Universidade do Minho

Trabalho Prático

Realizado no âmbito da Unidade Curricular de
Processamento e Recuperação de Informação

Madalena Passos (pg54023)

Mariana Almeida (pg54062)

Mariana Ribeiro (pg54061)

Docente: Óscar Gama

Conteúdo

Introdução	3
2. Descrição do Sistema	3
3. Implementação	5
3.1 Resumos	5
3.2 Grupo especializado de documentos	5
3.3 Lemas vs Stems	6
3.4 Query: OR, AND, NOT	7
3.5 Implementação do TF-IDF	8
4. Resultados e Discussão	9
5. Conclusão	19
6. Referências	20

Introdução

Na era da informação digital, a procura por conhecimento em ambientes académicos e científicos é constante e vital. Neste contexto, o presente trabalho prático visa explorar e aprimorar um sistema de recuperação de informação, utilizando como base o programa *PureHub* da *Universidade de Coventry*.

Este sistema amplia a eficácia da procura de artigos científicos através de diversas funcionalidades, permitindo a consulta destes através de títulos e resumos, a busca por documentos em formato PDF em áreas específicas, a escolha entre estratégias de indexação (lemas ou *stems*) e a execução de consultas complexas com operadores lógicos (AND, OR, NOT).

Assim, através de uma interface *web* simples e intuitiva, os utilizadores podem selecionar a base de dados, a estratégia de indexação, os operadores lógicos e os termos de pesquisa pretendidos obtendo resultados apresentados de forma ordenada, recorrendo à métrica TF-IDF e ao cálculo da similaridade de cossenos para efetuar o ranking desses artigos.

2. Descrição do Sistema

Para o desenvolvimento deste projeto, foi utilizado o *Streamlit*, uma biblioteca *Python* de código aberto que permite criar *web apps* interativas e a visualização de dados de forma rápida e amigável para o utilizador^[1].

O primeiro passo foi configurar o servidor no computador pessoal para garantir a execução, segurança, acessibilidade e escalabilidade do projeto. Isso incluiu a conexão do IDE (VSCode) ao Ubuntu e a criação de uma nova diretoria para armazenar os arquivos do projeto com o comando `mkdir TPRATICO`.

Após colocar o projeto na diretoria mencionada, foi necessário incluir o ficheiro *requirements.txt* do repositório do GitHub fornecido pelo docente ^[2] e executar o comando `pip install -r requirements.txt` para instalar as dependências do projeto. Além disso, a biblioteca *lxml* foi instalada com o comando `pip install lxml`.

Para completar a configuração do servidor, foi necessária a instalação do *Google Chrome* e do *Chromedriver* no ambiente Ubuntu, permitindo a navegação *web* na plataforma e, com isto, o projeto estava pronto para avançar no seu desenvolvimento.

Este projeto iniciou com um sistema base fornecido pelo docente[2], composto por várias partes principais: a configuração inicial das bibliotecas, o carregamento dos dados, a função de procura, a interface do utilizador e a recolha dos dados.

Procede-se inicialmente com a importação e configuração de bibliotecas essenciais como o *NLTK* e *Scikit-learn*, utilizadas para tarefas de processamento de linguagem natural e *machine learning*. Essas bibliotecas permitem o processamento e análise dos textos das publicações e dos perfis dos autores.

Os dados necessários para a busca são carregados a partir de arquivos JSON, que contêm informações detalhadas sobre publicações, autores, nomes, *URLs*, datas de publicação e afiliações à Universidade de Coventry. O carregamento desses dados é fundamental para que o sistema possa indexar e recuperar informações relevantes durante a busca.

A função de procura é o núcleo da aplicação. Ela permite realizar buscas tanto por publicações quanto por autores, utilizando operadores AND e OR. A função emprega a vetorização TF-IDF para transformar os textos em vetores de termos ponderados e, em seguida, calcula a similaridade do cosseno para determinar a relevância dos documentos em relação aos termos da *query* fornecida pelo utilizador.

Os resultados da busca são exibidos utilizando a função de exibição de resultados, que organiza e apresenta os dados em formato de cartões. Esta abordagem permite uma visualização rápida e intuitiva das informações, com detalhes importantes destacados para facilitar a sua compreensão.

Assim, tendo em conta as ferramentas já implementadas, o sistema proposto tem como objetivo disponibilizar as seguintes funcionalidades:

- Permitir a busca de *queries* em títulos e resumos de artigos científicos da Universidade de Coventry;
- Implementar um sistema de busca para um conjunto especializado de documentos em formato PDF;
- Permitir ao utilizador escolher entre diferentes estratégias de indexação: lemas ou *stems*;
- Implementar a busca com operadores lógicos AND, OR e NOT, quer com recurso a botões, quer na especificação da *query*;
- Implementar a métrica TF-IDF;
- Calcular o cosseno entre os vetores TF-IDF da *query* e dos documentos;
- Apresentar os resultados da consulta de acordo com o ranking do cosseno;
- Permitir ao utilizador aceder ao documento original através de um link.

Estas funcionalidades visam proporcionar uma experiência de busca eficiente e precisa, facilitando o acesso às informações académicas da Universidade de Coventry.

3. Implementação

A implementação do sistema de recuperação de informação envolveu diversas etapas que garantiram o cumprimento dos objetivos propostos.

3.1 Resumos

Para além dos títulos já extraídos no programa base, foi necessário extrair também os resumos para cada artigo científico produzido pela Universidade de *Coventry*. Desta forma, foi desenvolvido o *web scraper*, ***abstract.py***, que utiliza as bibliotecas *Selenium* e *BeautifulSoup* para extrair resumos de publicações a partir de *urls* fornecidos no dicionário *scraper_results.json*, este último gerado aquando da extração dos títulos.

Primeiramente, foram importados os módulos necessários para o funcionamento do *scraper*, bem como os módulos *json* e *ujson* para a manipulação de dados JSON.

Posteriormente, foi carregado o ficheiro JSON *scraper_results.json*. Este ficheiro, para além dos dados referentes ao título, data e autor, contém ainda informações sobre o *url* associado a cada artigo. Posto isto, todos os *urls* das publicações foram armazenados numa lista. Iterando sobre a lista, foram abertos todos os *urls* e feita uma requisição GET para permitir o acesso ao conteúdo da página. De forma a guardar apenas os *abstracts*, foi utilizado o *BeautifulSoup* que procurou por *divs* com a classe *textblock* para extrair os respetivos resumos das publicações. É de salientar que algumas das publicações não continham *abstracts*, sendo necessário um tratamento destes casos através da inserção de uma *string* “*No abstract*”.

Por fim, a lista de resumos extraídos foi guardada num ficheiro JSON, *pub_abstracts.json*. Numa etapa seguinte, que será explicada mais em detalhe a seguir, mostra-se como este ficheiro irá ser utilizado para a criação dos índices invertidos dos *stems* / *lemas* das palavras presentes nos *abstracts*. Estes índices serão utilizados para uma procura mais precisa e rápida de interrogações nos resumos dos artigos.

3.2 Grupo especializado de documentos

Para uma área de investigação específica como a saúde, foi escolhido um grupo especializado de documentos do *Centre for Intelligent Healthcare* (C.I.H) com cerca de 40 artigos científicos. O respetivo código Python implementado (***pds.py***) utilizou as bibliotecas *Selenium*, *BeautifulSoup* e *WeasyPrint* para automatizar a consulta e extração de artigos científicos em formato PDF. Inicialmente, foi utilizado o link principal, associado ao C.I.H para extrair todos os *urls* da página correspondentes aos artigos científicos:

<https://pureportal.coventry.ac.uk/en/organisations/ihw-centre-for-intelligent-healthcare-cih/publications/>

De seguida, todos os *urls* extraídos foram guardados numa lista, sendo que para cada elemento dessa lista, foi utilizado o *BeautifulSoup* para extraír todo o conteúdo HTML. Posteriormente, através da biblioteca *WeasyPrint*, foi convertido o conteúdo HTML em ficheiro PDF.

De forma a ser feita a procura nestes ficheiros, foi necessário guardá-los num dicionário como par chave-valor o nome do artigo e o seu conteúdo HTML. Mais uma vez, este dicionário será colocado num ficheiro *json* que permitirá a criação de índices invertidos dos *stems* / *lemas* que serão usados para a procura de interrogações nos *pdfs* dos artigos do grupo especializado.

3.3 Lemas vs Stems

Na fase de pré-processamento dos títulos, dos autores e dos *abstracts* foi necessário realizar quer a lematização (*lemas*) quer o *stemming* (*stems*) das palavras presentes nos documentos. A lematização transforma palavras nos seus lemas ou formas base, considerando o contexto e a morfologia. Já o *stemming* reduz as palavras para radicais, removendo sufixos e prefixos.

A escolha entre lemas e *stems* na procura irá influenciar a precisão e eficiência nos resultados obtidos. Uma vez que esta escolha será decida pelo utilizador, será necessário também aplicar o processo escolhido à interrogação realizada.

Posto isto, foram desenvolvidas *scripts* para cada um dos processos e para cada um dos dados textuais, de forma a realizar o pré-processamento dos mesmo e criar um índice invertido para facilitar a posterior procura.

Assim, numa etapa inicial, cada tipo de dado textual (títulos, autores, resumos e documentos especializados) foi dividido em *tokens*, usando a função *word_tokenize*. De seguida, foram removidos caracteres especiais, pontuações e *stop words*, que não apresentam relevância. Com o texto já tratado, foi possível a aplicação de um dos dois processos, através da função *WordNetLemmatizer()* ou da função *PorterStemmer()*.

Por fim, foi construído um índice invertido, onde cada palavra (*stem* ou *lema*) foi mapeada para uma lista de índices de documentos em que está presente. Os ficheiros resultantes serão utilizados no ficheiro *app.py* para a procura de interrogações.

3.4 Query: OR, AND, NOT

Para facilitar a procura e filtragem de informações, a aplicação permitiu a realização de consultas com os operadores lógicos como AND, OR e NOT. É importante ressaltar que estes operadores conseguem ser utilizados em simultâneo através da opção ‘*All operators*’, sendo necessário que o utilizador introduza os operadores pretendidos entre os termos (ex: ‘*hope AND health NOT individual*’) onde, posteriormente, os termos serão transformados em *lemas* ou *stems* (dependendo da escolha do utilizador).

A seguir será explicado, a lógica para a implementação dos operadores referidos anteriormente.

Operador AND

- O operador AND é ativado quando o utilizador seleciona a opção correspondente na interface do *Streamlit*.
- Este é usado para encontrar documentos que contenham todos os termos da consulta em simultâneo.
- A função *search_data ()* processa cada termo da consulta, identifica os documentos que os contêm e calcula a similaridade de cosseno (existem 2 opções de cálculo que irão ser explicadas mais à frente) entre os documentos e a *query*.
- Os documentos com todos os termos da query são retornados como resultados e apresentados através da função *show_results()*.

Operador OR:

- O operador OR é ativado quando o utilizador seleciona a respetiva opção na interface.
- Este é usado para encontrar documentos que contenham pelo menos um dos termos da consulta.
- A função *search_data ()* processa cada termo da *query*, identifica os documentos que o contêm e calcula a similaridade de cosseno entre os documentos e a *query*.
- Todos os documentos que contêm pelo menos um termo são retornados como resultados.

Operador NOT:

- O operador NOT é ativado quando o utilizador seleciona a opção na interface.
- Este é usado para encontrar documentos que não contenham o termo introduzido.
- A função *search_data ()* processa o termo , identifica os documentos que não o contêm e calcula a similaridade de cosseno entre os documentos e a *query*.

- Os documentos que não contêm o termo são retornados como resultados.

Operador ALL:

- O operador ALL é uma opção que possibilita a utilização de todos os operadores em simultâneo:

Operador OR:

- Inicialmente, como o operador OR tem prevalência sobre os restantes operadores, são identificadas as suas ocorrências no texto do *input*.
- Para cada ocorrência, são obtidas as palavras escritas antes e depois do operador e realizada a procura através da função já definida para o operador OR.
- Se já existirem resultados anteriores, o resultado obtido é intersetado com os novos resultados, caso contrário, são guardados os novos resultados.

Operador AND:

- O funcionamento deste operador é muito semelhante ao do operador OR, onde são identificadas as palavras imediatamente anteriores e posteriores ao operador.
- Posteriormente, é feita a procura através da função já definida para o operador AND e intersetado o resultado com os resultados anteriores.

Operador NOT:

- É identificada a palavra imediatamente a seguir ao operador NOT.
- A procura é feita excluindo todos os resultados que contenham a palavra.
- Mais uma vez, os resultados são intersetados com os anteriores.
- Esta operação é realizada em último lugar pela melhor eficiência em termos computacionais.

3.5 Implementação do TF-IDF

Para além da procura de interrogações em documentos, é fundamental avaliar a importância e relevância dos mesmos. Para tal, existem diversas técnicas, nomeadamente o TF-IDF (*Term Frequency-Inverse Document Frequency*) e a similaridade pelo cosseno.

De forma a ser possível medir a relevância e similaridade entre documentos, foram desenvolvidas duas possíveis implementações:

Função Sklearn: foi utilizada a função *cosine_similarity* da biblioteca *scikit-learn* para o cálculo da similaridade de cosseno e consequente ranking de documentos.

Implementação Manual: foi desenvolvida a função *cos_sim*, e outras funções auxiliares, que têm em conta as pontuações dadas pelo TF-IDF, calculado linearmente.

Relativamente à implementação personalizada, foram desenvolvidas algumas funções auxiliares que permitiram efetuar o cálculo TF-IDF.

Funções para Cálculo de TF-IDF:

- ***term_frequency(word, document)*:** Calcula a Frequência do Termo (TF) de uma palavra específica num documento. Retorna a proporção de vezes que a palavra aparece no documento em relação ao total de palavras.
- ***inverse_document_frequency(word, corpus)*:** Calcula a Frequência Inversa do Documento (IDF) de uma palavra na coleção de documentos. Utiliza o logaritmo da razão entre o número total de documentos e o número de documentos que contêm a palavra.
- ***TF_IDF(word, document, corpus)*:** Combina os valores TF e IDF para calcular a pontuação TF-IDF para uma palavra num documento em relação à coleção. Esta pontuação representa a importância relativa da palavra no contexto do documento.

Função para Vetorização TF-IDF:

- ***tf_idf_vectorizer(linha)*:** Cria vetores TF-IDF para cada *string* de uma lista de entrada. Cada vetor representa a importância de cada palavra no documento correspondente.

Função para Cálculo de Similaridade de Cosseno:

- ***cosseno_sim(doc, q)*:** Calcula a similaridade de cosseno entre duas matrizes, correspondentes à *query* e ao documento. É de notar que foi aplicada a normalização aos vetores, sendo que o produto interno dos dois representa o valor do cosseno pretendido.

4. Resultados e Discussão

De forma a analisar a eficácia da aplicação desenvolvida, foram efetuados vários testes e apresentados os resultados nesta secção.

Em primeiro lugar, para abrir a aplicação, é necessário executar o comando *streamlit run app.py*. De seguida, é então apresentada a página inicial, com diversas opções de procura em diferentes secções de artigos científicos, bem como diferentes operadores lógicos para a construção de *queries*.

Na Figura 1, está representado o menu principal da aplicação:




Figura 1- Menu principal.

Para a consulta de uma *query*, o utilizador deve escolher as opções que pretende, como por exemplo, o tipo de operador que pretende usar, em que parte do texto quer fazer a consulta, o tipo de estratégia de indexação e ainda o tipo de método de ranking de documentos.

De seguida, serão mostrados os testes que foram realizados.

Search research:

bariatric surgical

Search Filters

☒ AND ☐ OR ☐ NOT ☐ All operators

Search in:

☐ Titles ☒ Abstracts ☐ Authors ☐ C.I.H Documents

Select indexing strategy:

☒ Stemming ☐ Lemmatization

Choose ranking method:

☒ Sklearn Function ☐ Custom Implementation

SEARCH

Showing results for: 4

Figura 2- Consulta *query 1*: 'bariatric and surgical'.

Os resultados retornados para a consulta em *Abstracts* são apresentados da seguinte forma:

Jan 2022	Sept 2019	Nov 2020
Bariatric Surgery and COVID-19: What We Have Learned from the Pandemic in Iran: a Retrospective Observational Cohort Study Cain Clark ... Purpose: Little is known about the symptoms of coronavirus disease 2019 (COVID-19) on patients with morbid obesity following bariatric surgery (BS) in Iran. Thus, we sought to investigate the symptoms and effect of COVID-19 in patients with morbid obesity following, or candidates for, BS in Iran. Materials and Methods: In this retrospective observational cohort study, we enrolled 236 morbid obese patients following (surgical group) or candidates (nonsurgical group) for bariatric surgery. Demographics, probable COVID-19 incidence, acute and persistent COVID-19 symptoms, an ... Ranking: 0.13039 View	Bariatric surgery among older adults: a matched case-control study on 30-day and 5-year mortality and changes in Body Mass Index and HbA1c up to 5-years post-operatively Sally Abbott ... Introduction: Obesity is common (prevalence 30%) in older adults (≥65 years). Bariatric surgery (BS) is the most effective intervention resulting in sustained weight loss and cardiovascular and metabolic benefits. However, the outcomes of ... who had BS between 2003 and 2013 and all were matched to 2 'typical' aged controls (38 – 53 years old, the age IQR for BS patients at our centre) for surgical procedure, gender, referral body mass index (BMI) and diabetes status. Data were obtained from both local and GP records. Survival was compared between ... Ranking: 0.04442 View	Weight loss during medical weight management does not predict weight loss after bariatric surgery: a retrospective cohort study Sally Abbott ... Background: Many bariatric surgical centers mandate achieving weight loss targets through medical weight management (MWM) programs before offering bariatric surgery, but the evidence ... Ranking: 0.02314 View

Figura 3- Resultados retornados resultantes da *query 1*.

Como se pode observar na Figura 3, para cada resultado retornado são apresentados os seguintes elementos: o título do artigo, a data de publicação, o nome do autor, um excerto do texto com as

palavras procuradas destacadas, a classificação do artigo (ranking) , e uma hiperligação "View" que redireciona para a página completa do mesmo.

Search research:
health hope

Search Filters
☐ AND ☒ OR ☐ NOT ☐ All operators

Search in:
☒ Titles ☐ Abstracts ☐ Authors ☐ C.I.H Documents

Select indexing strategy:
☒ Stemming ☐ Lemmatization

Choose ranking method:
☐ Sklearn Function ☒ Custom Implementation

SEARCH

Showing results for: 60

Figura 4- Query 2: 'health or hope' com stemming aplicado.

2008	2014	10 Mar 2014
Hazel Barrett	Heaven Crawley	Hazel Barrett
<i>Health inequalities</i>	<i>Migration and Health in Wales</i>	<i>From 'health inequality' to 'health inequity': The move to a moral paradigm in global health disparity</i>
View	View	View
Ranking: 0.70711	Ranking: 0.57735	Ranking: 0.45883
1 Apr 2018	1 Feb 2021	28 Aug 2019
Joel Busher	Mahdi Bashiri	Laurence J Baldwin
<i>Hopes and Fears: Community cohesion and the 'White working class' in one of the 'failed spaces' of multiculturalism</i>	<i>A matheuristic algorithm for stochastic home health care planning</i>	<i>Nursing Skills for Children and Young People's Mental Health</i>
View	View	View
Ranking: 0.44721	Ranking: 0.37796	Ranking: 0.35355

Figura 5- Resultados retornados resultantes da query 2.

É possível observar que os resultados apresentados contêm a data, o nome do autor, o título do artigo científico, o ranking e ainda uma hiperligação ‘View’ que redireciona para a página do mesmo.

Search research:
health hope

Search Filters
☐ AND ☒ OR ☐ NOT ☐ All operators

Search in:
☒ Titles ☐ Abstracts ☐ Authors ☐ C.I.H Documents

Select indexing strategy:
☐ Stemming ☒ Lemmatization

Choose ranking method:
☐ Sklearn Function ☒ Custom Implementation

SEARCH

Showing results for: 59

Figura 6- Query 3: ‘health or hope’ com lematização.

2008	Feb 2023	2014
Hazel Barrett	Anna Bogush	Heaven Crawley
<i>Health inequalities</i>	<i>Spatial estimation of groundwater quality, hydrogeochemical investigation, and health impacts of shallow groundwater in Kabul city, Afghanistan</i>	<i>Migration and Health in Wales</i>
View	View	View
Ranking: 0.70711	Ranking: 0.61237	Ranking: 0.57735
10 Mar 2014	1 Feb 2021	28 Aug 2019
Hazel Barrett	Mahdi Bashiri	Laurence J Baldwin
<i>From 'health inequality' to 'health inequity': The move to a moral paradigm in global health disparity</i>	<i>A matheuristic algorithm for stochastic home health care planning</i>	<i>Nursing Skills for Children and Young People's Mental Health</i>
View	View	View
Ranking: 0.48507	Ranking: 0.37796	Ranking: 0.35355

Figura 7- Resultados retornados resultantes da query 3.

Através da visualização das imagens 5 e 7, observa-se que foram obtidos, para a mesma query , 60 e 59 resultados com a técnica de stemmerização e lematização, respetivamente. Apesar da

ligeira diferença no número de resultados, a relevância dos documentos retornados pela lematização foi maior.

Estes resultados podem ser explicados pelas diferenças em ambos os processos, uma vez que o *stemming* produz mais resultados ao incluir várias variações de palavras que podem não ser relevantes. Já a lematização, por considerar o contexto, retorna resultados mais precisos e úteis.

Desta forma, a lematização, apesar de retornar menos resultados, proporciona maior relevância e precisão. Assim, a escolha mais adequada deve ser aquela que satisfaz melhor as necessidades do utilizador.

Por outro lado, é também possível a utilização de todos os operadores numa só *query*. Para isso, o utilizador deve escolher a opção ‘All operators’ e incluir explicitamente os operadores pretendidos. Na Figura 8, está representado um exemplo de utilização.

The screenshot displays a search interface with the following elements:

- Search research:** A text input field containing the query "health or people and matters".
- Search Filters:** Radio buttons for "AND", "OR", "NOT", and "All operators" (which is selected).
- Search in:** Radio buttons for "Titles", "Abstracts" (selected), "Authors", and "C.I.H Documents".
- Select indexing strategy:** Radio buttons for "Stemming" (selected) and "Lemmatization".
- Choose ranking method:** Radio buttons for "Sklearn Function" (selected) and "Custom Implementation".
- SEARCH** button.
- Showing results for: 5**
- Results:** A table with three columns showing search results. The first column has a date "1 Nov 2016", the second "2012", and the third "25 Mar 2011". Each column contains a title, a snippet, and an author.

1 Nov 2016	2012	25 Mar 2011
What really matters in children and young people's mental health	Tackling sensitive issues using a game-based environment: serious game for relationships and sex education (RSE)	They seem to think we're better than you": Framing football support as a matter of 'national identity'
Laurence J Baldwin	Samantha Clarke	Jackie Abell
* ... The Values-Based Child and Adolescent Mental Health System Commission was set up by the Royal College of Psychiatrists, YoungMinds and the Children & Young People's Mental Health Coalition to give a fr ... lues-Based Child and Adolescent Mental	 Experiencing sexual coercion during adolescence can lead to adverse psychological and physical health outcomes for those affected. Eliminating such experiences is important for enhancing adolescent	 resident in England and Scotland, whereas in Scotland national football support is treated as a matter of national identity for Scottish and English people, in England it is separated from a collective sense of English identity.

Figura 8- Query 4: ‘health or people and matters’ e resultados retornados resultantes da query.

Com o objetivo de demonstrar a eficácia do operador NOT, foi utilizado um termo presente no primeiro documento da *query* anterior. Assim, o expectável será a procura retornar menos um documento relativamente ao anterior, isto é, não retornar o primeiro documento.

The screenshot shows a search interface with the following elements:

- Search research:** A text input field containing the query "health or people and matters not Commission".
- Search Filters:** Radio buttons for "AND", "OR", "NOT", and "All operators". "All operators" is selected.
- Search in:** Radio buttons for "Titles", "Abstracts", "Authors", and "C.I.H Documents". "Abstracts" is selected.
- Select indexing strategy:** Radio buttons for "Stemming" and "Lemmatization". "Stemming" is selected.
- Choose ranking method:** Radio buttons for "Sklearn Function" and "Custom Implementation". "Sklearn Function" is selected.
- SEARCH** button.
- Showing results for: 4** (indicated in a blue bar).
- Results:** A table with 3 columns showing document details.

2012	25 Mar 2011	Nov 2017
Tackling sensitive issues using a game-based environment: serious game for relationships and sex education (RSE)	They seem to think we're better than you": Framing football support as a matter of 'national identity'	Hospitality in a Time of Terror: Strangers at the Gate
Samantha Clarke	Jackie Abell	Lindsay Balfour
... .. Experiencing sexual coercion during adolescence can lead to adverse psychological and physical	 resident in England and Scotland, whereas in Scotland national football support is treated as a matter of national identity	 hics is so provocatively raised or disavowed by a predominantly visual and cultural archive that has been and continues to be consumed by millions of
health outcomes for those affected. Eliminating such	for Scottish and English people , in England it is	people around the world. This book utilizes works of

Figura 9- Query 5: 'health or people and matters not Commission' e resultados retornados resultantes da *query*.

A Figura 9 corrobora o esperado, mostrando que são apenas retornados 4 documentos.

Em termos de método de ranking, foi necessário comparar os resultados de classificação obtidos entre a função do *scikit-learn* (cálculo *tf-idf* logarítmico) e a função desenvolvida manualmente (cálculo *tf-idf* linear). A mesma consulta foi testada num cenário idêntico, variando apenas o tipo de opção de classificação utilizada.

Search research:

Search Filters
☐ AND ☐ OR ☐ NOT ☒ All operators

Search in:
☒ Titles ☐ Abstracts ☐ Authors ☐ C.I.H Documents

Select indexing strategy:
☒ Stemming ☐ Lemmatization

Choose ranking method:
☒ Sklearn Function ☐ Custom Implementation

Showing results for: 17

28 Aug 2019 Laurence J Baldwin <i>Nursing Skills for children and Young People's Mental Health</i> View Ranking: 0.19446	2014 Jane Coad <i>Social spaces for young children in hospital</i> View Ranking: 0.18185	1 Nov 2016 Laurence J Baldwin <i>What really matters in children and young people's mental health</i> View Ranking: 0.17454
3 Aug 2019 Laurence J Baldwin <i>What nursing skills are we using with children and young people who experience mental health difficulties?</i> View Ranking: 0.14255	2016 Jane Coad <i>An evidence analysis in the use of blended diet for children and young people.</i> View Ranking: 0.14064	1 Mar 2015 Jane Coad <i>An exploration of the data collection methods utilised with children, teenagers and young people (CTYPs)</i> View Ranking: 0.11944

Figura 10- Query 6: ‘children and young’
e resultados retornados com o método *scikit-learn* .

Search research:
children and young

Search Filters
☐ AND ☐ OR ☐ NOT ☒ All operators

Search in:
☒ Titles ☐ Abstracts ☐ Authors ☐ C.I.H Documents

Select indexing strategy:
☒ Stemming ☐ Lemmatization

Choose ranking method:
☐ Sklearn Function ☒ Custom Implementation

SEARCH

Showing results for: 17

2014 Jane Coad <i>Social spaces for young children in hospital</i> View Ranking: 0.44721	28 Aug 2019 Laurence J Baldwin <i>Nursing Skills for Children and Young People's Mental Health</i> View Ranking: 0.35355	1 Nov 2016 Laurence J Baldwin <i>What really matters in children and young people's mental health</i> View Ranking: 0.35355
2016 Jane Coad <i>An evidence analysis in the use of blended diet for children and young people.</i> View Ranking: 0.33333	Mar 2014 Jane Coad <i>Young children's perspectives of ideal physical design features for hospital-built environments</i> View Ranking: 0.31623	2012 Heaven Crawley <i>Working with Children and Young People Subject to Immigration Controls: Guidelines for Best Practice</i> View Ranking: 0.30151

Figura 11- Query 7 ‘children and young’
e resultados retornados com *custom implementation*.

Os resultados de classificação obtidos pela função do *scikit-learn* utilizam uma abordagem logarítmica para o cálculo do *tf-idf* enquanto que os resultados de uma função manual, que implementa uma abordagem linear para o mesmo cálculo.


Através da análise das figuras 10 e 11, é possível concluir que os rankings gerados pela função manual são mais altos comparativamente aos obtidos pela função do *scikit-learn*. Este facto sugere que o método manual está a atribuir uma importância maior aos documentos com termos de procura frequentes, resultando em rankings mais elevados.

Desta forma, os resultados obtidos podem ser consequência de a função logarítmica do $tf-idf$ ($w = 1 + \log(tf) / idf$) tender a suavizar a influência de palavras muito frequentes, evitando que os documentos com muitos termos repetidos dominem os resultados. Consequentemente, esta ponderação pode levar a uma classificação mais equilibrada e relevante em cenários onde termos comuns não devem ter um peso desproporcional.

É de salientar ainda que a função linear ($tf * idf$) é mais direta e pode atribuir maior importância a termos que apareçam frequentemente no documento, resultando em rankings mais altos.

Para além das funcionalidades já referidas, o utilizador tem também a possibilidade de realizar uma consulta dentro de uma área de investigação específica, neste caso numa coleção de 40 artigos científicos do *Centre for Intelligent Healthcare*.

Os resultados retornados são apresentados ao utilizador em forma de *url*, que redireciona para um documento em formato pdf.



Search research:

hope or security

Search Filters

☐ AND ☐ OR ☐ NOT ☒ All operators

Search in:

☐ Titles ☐ Abstracts ☐ Authors ☒ C.I.H Documents

Select indexing strategy:

☒ Stemming ☐ Lemmatization

Choose ranking method:

☒ Sklearn Function ☐ Custom Implementation

SEARCH

Showing results for: 3

View PDF 16	View PDF 6	View PDF 0
Ranking: 0.04286	Ranking: 0.02995	Ranking: 0.00618

Results shown for: 3

By Madalena Passos, Mariana Almeida and Mariana Ribeiro

Figura 12- Resultado da pesquisa da query 12: 'hope or security' na coleção C.I.H.

Adicionalmente, o utilizador é ainda capaz de consultar 40 documentos em formato PDF presentes na coleção:




Figura 13- Documentos em formato pdf disponíveis da coleção C.I.H.

5. Conclusão

O principal objetivo deste trabalho baseava-se na exploração e aprimoração de um sistema de recuperação de informação baseado no programa *PureHub* da Universidade de *Coventry*. Este sistema foi projetado para melhorar a eficácia da procura de artigos científicos através de funcionalidades como a consulta por títulos, resumos, autores, documentos em formato PDF, a escolha entre estratégias de indexação (lemas ou *stems*) e a execução de consultas complexas com operadores lógicos (AND, OR, NOT).

Os resultados demonstraram que o sistema desenvolvido conseguiu efetivamente ampliar a capacidade de recuperação de informações relevantes. A comparação entre as técnicas de *stemming* e lematização revelou que a lematização, embora retorne um número ligeiramente

menor de resultados, proporciona maior relevância e precisão. Além disso, os rankings gerados pela função manual de TF-IDF linear foram mais altos comparados aos obtidos pelo método logarítmico do *scikit-learn*, sugerindo uma maior importância atribuída aos documentos com termos de procura frequentes pela abordagem manual.

Apesar dos resultados positivos, há espaço para melhorias no sistema. Futuras versões podem incluir o aprimoramento do algoritmo de ranking através de algoritmos mais sofisticados que possam balancear melhor a importância dos termos de pesquisa, a expansão da base de dados para uma busca mais abrangente e o desenvolvimento de novas funcionalidades como filtros avançados, a implementação de recomendações de artigos baseadas em procuras anteriores, e alertas de novas publicações relacionadas aos interesses do utilizador.

Essas melhorias podem potencializar ainda mais a eficácia do sistema de recuperação de informações, tornando o processo mais personalizado para cada utilizador.

6. Referências

- [1] R. L. Soares, "Construindo Dashboards e Data Apps com Streamlit," Blog DP6, 23 de agosto de 2020. [Online]. Disponível: <https://blog.dp6.com.br/construindo-dashboards-e-data-apps-com-streamlit-afac87962ba0>. [Acedido: 20 de maio de 2024]
- [2] Maladeep, "Coventry PureHub Search Engine," Repositório GitHub, junho de 2021. [Online]. Disponível: <https://github.com/maladeep/Coventry-PureHub-Search-Engine>. [Acedido: 20 de maio de 2024]